



自动编码器

主讲人：吴昊

实例引入

下面有两组数字，哪组更容易记忆呢？

40, 27, 25, 36, 81, 57, 10, 73, 19, 68

50, 25, 76, 38, 19, 58, 29, 88, 44, 22, 11, 34, 17, 52, 26, 13, 40, 20


乍一看可能觉得第一行数字更容易记忆，毕竟更短。但仔细观察就会发现，第二组数字是有规律的：偶数后面是其二分之一，奇数后面是其三倍加一（这就是著名的hailstone sequence）。如果识别出了这一模式，第二组数据只需要记住这两个规则、第一个数字、以及序列长度。当然，如果你的记忆能力超强，可以记住很长的随机数字序列，那你可能就不会去关心一组数字是否存在规律了。

实例引入

国际象棋大师观察棋盘5秒，就能记住所有棋子的位置，而常人是无法办到的。但棋子的摆放必须是实战中的棋局（也就是棋子存在规则，就像第二组数字），棋子随机摆放可不行（就像第一组数字）。象棋大师并不是记忆力优于我们，而是经验丰富，很擅于识别象棋模式，从而高效地记忆棋局。

上述两个例子都充分说明了探究数据中核心内容的重要性，也是自编码的关键目标。和记忆模式类似，一个自编码器接收输入，将其转换成高效的内部表示，然后再输出输入数据的类似表达。自编码器通常包括两部分：encoder（也称为识别网络）将输入转换成内部表示，decoder（也称为生成网络）将内部表示转换成输出。



正如右图所示，除了输入神经元和输出神经元的个数相等，自编码器的结构和多层感知机类似。在右图的例子中，自编码器只有一个包含2个神经元的隐层（encoder），以及一个包含3个神经元的输出层（decoder）。输出是在损失函数的约束下设法高精度地重建输入。



参考<https://www.cnblogs.com/royhoo/p/Autoencoders.html>


自动编码器结构

自动编码器就是一种尽可能复现输入信号的神经网络（典型情况）。在我们之前的神经网络中，我们输入的样本是有标签的，即 (input, target)，这样我们根据当前输出和target (label) 之间的差去改变前面各层的参数，直到收敛。



自动编码器结构

搭建一个自动编码器需要完成下面三样工作：搭建编码器，搭建解码器，设定一个损失函数，用以衡量由于压缩而损失掉的信息。编码器和解码器一般都是参数化的方程，典型情况是使用神经网络。编码器和解码器的参数可以通过最小化损失函数而优化。



自动编码器性质

自动编码器 (Autoencoder, AE)，就是一种利用反向传播算法使得输出值等于输入值的神经网络，它现将输入压缩成潜在空间表征，然后将这种表征重构为输出。所以，从本质上来讲，自编码器是一种数据压缩算法，其压缩和解压缩算法都是通过神经网络来实现的。自编码器有如下三个特点：

数据相关性。就是指自编码器只能压缩与自己此前训练数据类似的数据，比如说我们使用MNIST训练出来的自编码器用来压缩人脸图片，效果肯定会很差。再比如，使用人脸训练出来的自动编码器去压缩树木等别的图片，效果也会很差，因为它学习到的特征是与人脸相关的。

数据有损性。自编码器在解压时得到的输出与原始输入相比会有信息损失，所以自编码器是一种数据有损的压缩算法。MP3，JPEG等压缩算法也是如此，这与无损压缩算法不同。


自动学习性。自动编码器是从数据样本中自动学习的，这意味着很容易对指定类的输入训练出一种特定的编码器，而不需要完成更多的其它工作。

参考https://blog.csdn.net/weixin_37737254/article/details/102920262

自动编码器应用

目前自动编码器的应用主要有两个方面。

第一是数据去噪。具体地，训练样本集包含许多噪声图像和它们对应的无噪声图像。基于未经优化的自动编码器，以噪声图像为输入生成的随机去噪结果，再和对应的无噪声图像进行对比。利用代价函数，反过来调节、优化整个网络中的参数。随着大量训练样本对网路进行训练，网络就具备了去噪的能力。右图为部分噪声图像和对应的去噪结果。





自动编码器应用

第二是为进行可视化而降维，自动编码器的核心价值在于经编码器压缩后的潜在空间表征。上面我们提到自动编码器是一种数据有损的压缩算法，经过这种有损的数据压缩，我们可以学习到输入数据种最重要的特征。

自动编码器是一种数据的压缩算法，其中数据的压缩和解压缩函数是数据相关的、有损的、从样本中自动学习的。在大部分提到自动编码器的场合，压缩和解压缩的函数是通过神经网络实现的。

例如我们输入图像，自动编码器可以将这个图像上“人脸”的特征进行提取(编码过程)，这个特征就保存为自动编码器的潜变量。例如这张人脸的肤色以及头发颜色，自动编码器在提取出这些特征之后还可以通过这些特征还原我们的原始数据。这个过程称作“解码”。




欠完备自编码器

由上述自编码器的原理可知，当隐层单元数大于等于输入维度时，网络会发生完全记忆的情况。为了避免这种情况，我们限制隐层的维度一定要比输入维度小，这就是欠完备自编码器。如下图所示，学习欠完备的表示将强制自编码器捕捉训练数据中最显著的特征。

欠完备自编码器特点：

防止过拟合，并且因为隐层编码维数小于输入维数，可以学习数据分布中最显著的特征。

若中间隐层单元数特别少，则其表达信息有限，会导致重构过程比较困难。




稀疏自编码器

稀疏自编码器是加入正则化的自编码器，其未限制网络接收数据的能力，即不限制隐藏层的单元数。所谓稀疏性限制是指：

若激活函数是sigmoid，则当神经元的输出接近于1的时候认为神经元被激活，输出接近于0的时候认为神经元被抑制。使得大部分神经元被抑制的限制叫做稀疏性限制。若激活函数是tanh，则当神经元的输出接近于-1的时候认为神经元是被抑制的。

如右图所示，浅色的神经元表示被抑制的神经元，深色的神经元表示被激活的神经元。通过稀疏自编码器，我们没有限制隐藏层的单元数，但是防止了网络过度记忆的情况。




降噪自编码器

降噪自编码器是一种接受损失数据作为输入，用训练模型预测出原始未被损坏数据，并将其作为输出的自编码器。


前述模型希望我们的自编码器足够敏感以重构原始观察的结果，但又要对训练数据不够敏感，以至于模型学习到通用的编码和解码能力。采用这种方法，我们的模型不能简单地开发一个记忆训练数据的映射，因为我们的输入和目标输出不再相同。

此时，采用利用另一种开发通用化模型的策略，即将略微破坏的数据作为输入，但仍维持未损坏的数据作为目标输出。



卷积自编码器


卷积自编码器和普通自编码器的区别在于encoder和decoder都是卷积神经网络。相应的，encoder使用的是卷积操作和池化操作，而decoder使用的反卷积操作和反池化操作，关于卷积、反卷积、池化和反池化的过程实例如右图所示。




变分自编码器

变分自编码器（VAE）以概率的方式描述潜在特征属性。具体地，不会构建一个定量描述潜在状态属性的编码器，而是构建一个利用概率分布描述潜在属性的编码器。

在前述的示例中，我们使用单个值来描述输入图像的潜在属性。但我们可能更倾向于将每个潜在属性表示为可能值的范围。例如，如果输入蒙娜丽莎的照片，你会为微笑属性分配什么样的单值？使用变分自编码器，我们可以用概率术语来描述潜在属性。




vs.



变分自编码器

通过这种方法，我们将输入的每个潜在属性表示为概率分布。当从潜在状态解码时，我们从每个潜在状态分布中随机采样，生成一个向量作为解码器模型的输入。




注意：对于变分自编码器，编码器模型有时被称为识别模型（recognition model），而解码器模型有时被称为生成模型。

参考https://zhuanlan.zhihu.com/p/64485020?from_voters_page=true

变分自编码器

对于编码器模型输出的可能值范围（统计分布），我们将随机采样这些值以供给我们的解码器模型，我们实质上实施了连续，平滑的潜在空间表示。对于潜在分布的所有采样，我们期望我们的解码器模型能够准确重构输入。因此，在潜在空间中彼此相邻的值应该与非常类似的重构相对应。



总结

自编码器是一种神经网络架构，能够发现数据中的结构，以便实现输入数据的压缩表示。

其核心目标是确保压缩后获取更具代表性、更有意义的属性；通常自编码器的最大挑战，是让模型学习到有意义、可泛化的潜在空间表征能力。

因为自编码器主要利用训练数据集中发现的属性来压缩数据，所以这些模型通常仅能够重构与训练集中样本相似的数据。

自编码器可以应用到如下几个领域：

01

异常检测

02

数据去噪

03

图像修复

04

信息检索