



自然语言处理

NLP是语言学、计算机科学和人工智能的一个子领域

- NLP的目标：让计算机能够**理解**和**生成**人类语言，让人们更高效地进行信息处理、知识管理和跨语言沟通。
- NLP的需求：沟通和语言、机器的使用、与机器交流。





自然语言处理任务

NLP任务具体分为NLU和NLG

自然语言处理 (NLP)

自然语言理解 (NLU)

自然语言的理解就是希望机器可以和人一样，有理解他人语言的能力。

- 1) 关注**理解**自然语言
- 2) 任务包括**分词、词性标注、命名实体识别**等
- 3) 将自然语言转化为计算机可理解的形式

自然语言生成 (NLG)

自然语言的生成就是将非语言格式的数据转换成人类的语言格式，以达到人机交流的目的。

- 1) 关注**生成**自然语言
- 2) 任务包括**文本规划、句法生成、词汇选择**等
- 3) 将计算机内部信息转化为自然语言文本

- **自然语言理解**
NLU, Natural Language Understanding
- **自然语言生成**
NLG, Natural Language Generation




**焦点、任务、方向
不同**



自然语言处理任务

NLU和NLG任务侧重不同



三 自然语言处理挑战

挑战一：歧义性表达

- 世界上有 6500 多种语言，它们都有自己的句法和语义规则。
- 机器要理解自然语言，首先需要将其转化为可以解释的东西。

▶ 以中文分词为例

▶ 不同的语言环境中的同形异构现象，按照具体语言环境的语义进行切法。

▶ 交叉歧义

▶ 他 / 说 / 的 / 确实 / 在理

▶ 组合歧义

▶ 两 **个** / **人** / 一起 / 过去、**个** **人** / 问题

▶ 从 **马** / **上** / 下来、**马** **上** / 就 / 来

▶ 句子级歧义

▶ **白** **天** **鹅** 在水里游泳

▶ 该 **研** **究** **所** 获得的成果

} 伪歧义



三 自然语言处理挑战

挑战二：上下文理解

- 上下文理解需要计算机能够理解和分析文本中的语境和语义关系，以便正确地理解文本的含义。

示例

- 平时很熟的曲子，今天却总是弹不准。不过米饭没熟，还要再蒸一会儿，咱们再练练。

分析

- '熟'被使用了两次，两次的含义不同。

挑战三：成语、俚语、歇后语的理解

- 成语、俚语和歇后语是人们日常用语中常见的表达方式，它们通常具有特殊的含义或用法。

示例

- 这词的任务小菜一碟。

分析

- 机器可能会理解为“这是一碟小菜”。

三 自然语言处理 – N-Gram模型

N-Gram是一种基于统计的技术

基本思想

- 大小为N的滑动窗口对文本内容进行操作 → 形成长度为N的字节片段序列
- 统计gram, 过滤 → 形成关键gram列表, 即文本的向量特征空间

基于假设

- 第N个词的出现只与前面N-1个词相关, 而与其它任何词都不相关
→ 整句的概率就是各个词出现概率的乘积



<https://blog.csdn.net/songbinxu>

Bi-gram : {I, love}, {love, deep}, {love, deep}, {deep, learning}

Tri-gram : {I, love, deep}, {love, deep, learning}

自然语言处理 – N-Gram模型

二元语言模型Bi-Gram

表1

i	want	to	eat	chinese	food	lunch	spend
2533	927	2417	746	158	1093	341	278

表2

	i	want	to	eat	chinese	food	lunch	spend
i	5	827	0	9	0	0	0	2
want	2	0	608	1	6	6	5	1
to	2	0	4	686	2	0	6	211
eat	0	0	2	0	16	2	42	0
chinese	1	0	0	0	0	82	1	0
food	15	0	15	0	1	4	0	0
lunch	2	0	0	0	0	1	0	0
spend	1	0	1	0	0	0	0	0

表3

	i	want	to	eat	chinese	food	lunch	spend
i	0.002	0.33	0	0.0036	0	0	0	0.00079
want	0.0022	0	0.66	0.0011	0.0065	0.0065	0.0054	0.0011
to	0.00083	0	0.0017	0.28	0.00083	0	0.0025	0.087
eat	0	0	0.0027	0	0.021	0.0027	0.056	0
chinese	0.0063	0	0	0	0	0.52	0.0063	0
food	0.014	0	0.014	0	0.00092	0.0037	0	0
lunch	0.0059	0	0	0	0	0.0029	0	0
spend	0.0036	0	0.0036	0	0	0	0	0

已知概率值

$P(i | \langle s \rangle) = 0.25$; $P(\text{chinese} | \text{want}) = 0.11$;
 $P(\text{food} | \text{chinese}) = 0.5$; $P(\langle /s \rangle | \text{food}) = 0.68$;
 $P(\text{want} | \langle s \rangle) = 0.25$;

判断哪个句子更合理

- $s1 = \langle s \rangle i \text{ want chinese food} \langle /s \rangle$
- $s2 = \langle s \rangle \text{ want } i \text{ chinese food} \langle /s \rangle$

$$P(s1) = P(i | \langle s \rangle) P(\text{want} | i) P(\text{chinese} | \text{want}) P(\text{food} | \text{chinese}) P(\langle /s \rangle | \text{food}) \\ = 0.25 \times 0.33 \times 0.0011 \times 0.5 \times 0.68 = 0.000031$$

$$P(s2) = P(\text{want} | \langle s \rangle) P(i | \text{want}) P(\text{chinese} | \text{want}) P(\text{food} | \text{chinese}) P(\langle /s \rangle | \text{food}) \\ = 0.25 \times 0.0022 \times 0.0011 \times 0.5 \times 0.68 = 0.0000002057$$

三 自然语言处理 – HMM

HMM , Hidden Markov Model, 隐马尔可夫模型

N-Gram缺点

- 缺乏长期依赖性：只能建模到前n-1个词-- 无法正确理解句子或识别复杂语言结构
- 数据稀疏性：大量词汇组合时，训练样本不足-- 某些词汇组合在语料库很少出现，模型无法很好训练
- 模型巨大：n增大，模型参数量呈指数增长-- 需要更多存储、计算资源

HMM优势

- 状态转移：捕捉词之间的依赖关系-- 根据历史信息推测未来状态
- 模型简单，易实现：参数数量相对较少-- 学习复杂度较低

$$P(O|S) = \prod_{i=1}^T P(O_t|S_t)P(S_t|S_{t-1})$$

其中， O 表示观测序列， S 表示状态序列， T 表示序列的长度。 $P(O_t|S_t)$ 表示在状态 S_t 下观测到观测值 O_t 的概率， $P(S_t|S_{t-1})$ 表示从状态 S_{t-1} 转移到状态 S_t 的概率。

自然语言处理 – CRF


CRF, Conditional Random Field, 条件随机场

HMM缺点

- **局部信息**: 当前单词只依赖当前标签, 当前标签只依赖前一个标签-- 只能定义相应类型的特征函数


CRF优势

- **全局信息**: 引入特征向量, 捕捉序列数据的局部依赖关系-- 包括词语本身特征和上下文特征




自然语言处理发展历程

自 2012 年开始，随着的深度学习的热潮，NLP开始基于DL进行端到端的训练。



自然语言处理发展历程


自然语言处理技术ChatGPT引起了新一代人工智能技术的变革






自然语言处理 - 分布式表征

分布式表征是NLP的基础



CBOW




Skip-gram

<i>cat</i>	→	0.6	0.9	0.1	0.4	-0.7	-0.3	-0.2
<i>kitten</i>	→	0.5	0.8	-0.1	0.2	-0.6	-0.5	-0.1
<i>dog</i>	→	0.7	-0.1	0.4	0.3	-0.4	-0.1	-0.3
<i>houses</i>	→	-0.8	-0.4	-0.5	0.1	-0.9	0.3	0.8


<i>man</i>	→	0.6	-0.2	0.8	0.9	-0.1	-0.9	-0.7
<i>woman</i>	→	0.7	0.3	0.9	-0.7	0.1	-0.5	-0.4
<i>king</i>	→	0.5	-0.4	0.7	0.8	0.9	-0.7	-0.6
<i>queen</i>	→	0.8	-0.1	0.8	-0.9	0.8	-0.5	-0.9

词

词向量



词语义越相近，
其向量距离越小



语义关系可由词
之间的加减运算，
- 知识推理

词向量空间分布

自然语言处理 - Transformer



Transformer -- Encoder-Decoder

Word2vec缺点

- 语义信息缺失：忽略词与词的语义关系 -- 语义表达不精准
- 固定上下文窗口大小：不适用多义词和复杂词汇 -- 无法精准反映目标词的含义

Transformer优势

- 自注意力机制：序列中的长距离依赖关系 -- 小区vs关注
- 不同上下文窗口大小：提高语义表示精度和鲁棒性 -- 房价vs(小区、关注)



自然语言处理 - BERT



BERT -- Encoder

Transformer缺点

- 长序列处理效率低 -- 单词vs所有单词计算相似度
- 训练数据量大 -- 编码器-解码器结构参数多，需要更多数据训练

BERT优势

- MLM更好学习上下文信息和语义表示 -- 要求模型同时理解上下文语境和单词之间的关系
- NSP学习句子级别语义表示 -- 要求模型理解句子之间的关系




自然语言处理 - GPT系列

GPT系列 -- Decoder

GPT-3是比GPT-2规模更大的模型，GPT-3拥有1.75万亿个参数，而GPT-2只有1.5亿个参数

- 提高自然语言处理的效果 -- 大规模语料库+解码器
- 支持多种自然语言处理任务 -- 预训练-微调优化模式
- 减少数据需求 -- 预训练采用大规模无监督学习的方式
- 改善模型的泛化能力 -- 通用语言表示+Tricks

- GPT-2生成文本速度较慢，需加速优化
- GPT只能生成单向的文本，受限使用范围，生成文本可能语义不一致、重复



GPT系列模型框架

自然语言处理 – GPT系列

GPT大力出奇迹的典范：大数据、大模型、大算力

GPT-3: 1.75万亿参数量，训练一次消耗1200万美元

模型	发布年份	参数量	发布公司	训练算力
GPT-1	2018	1.17亿	OpenAI	140 TFLOPS
GPT-2	2019	1.5亿-15亿	OpenAI	1.4 PFLOPS
BERT-base	2018	1.1亿	Google	340 GFLOPS
BERT-large	2018	3.4亿	Google	1.3 PFLOPS
RoBERTa	2019	3.5亿	Facebook	1.6 PFLOPS
ALBERT	2019	1.7亿-18亿	Google	200 GFLOPS
T5	2020	11亿	Google	4.6 PFLOPS
GPT-3	2020	1.75万亿	OpenAI	285 PFLOPS



自然语言处理 - ChatGPT

ChatGPT表现为对话机器人，能理解自然语言，进行多轮高质量对话

- 仅用两个月时间，月活跃用户已达1亿，是史上用户增速最快的消费应用
- ChatGPT不开源，其参数规模，技术细节都没有对外公布

ZH

什么是人工智能？



人工智能（Artificial Intelligence，AI）是一种让计算机能够像人类一样思考、学习和执行任务的技术。它的目标是使计算机能够模仿人类的智能，包括理解语言、感知世界、推理和决策等方面。人工智能可以利用机器学习、深度学习、自然语言处理、计算机视觉等技术，从大量的数据中学习和提取规律，进而自动化地执行各种任务。它可以应用于各种领域，如自然语言处理、图像识别、智能交通、智能家居、金融风控等，为人类创造更多的价值和便利。

ZH

你的智能技术包含哪些？



作为一名大型语言模型，我的智能技术包括自然语言处理、机器学习、深度学习等。其中自然语言处理是我最为突出的特点，我可以理解和生成自然语言的文本，可以对输入的文本进行分析、分类、摘要、翻译、生成等多种任务。同时，我也可以基于大量的数据进行机器学习和深度学习，以便更好地为用户提供信息和解决问题。在这些技术的支持下，我能够回答各种各样的问题，提供文本摘要、翻译和生成等服务，以满足用户的需求。

ZH

详细举例



好的，以下是一些我可以做的详细例子：

1. 自然语言理解：我可以分析用户输入的自然语言文本，并对其进行分类、实体识别、情感分析等任务。例如，用户输入一句话“今天天气真好”，我可以识别其中的实体“今天”和“天气”，并分析出句子的情感为“积极”。
2. 问答系统：用户输入一个问题，我可以利用机器学习和自然语言处理技术来理解问题，然后在我的知识库中查找相关信息，并给出最佳答案。例如，用户输入“什么是人工智能”，我可以给出简洁易懂的解释。

ChatGPT人工智能里程碑式的突破

ZH

今天天气如何？



很抱歉，作为一名语言模型，我没有实时的天气信息。如果您需要了解今天的天气，您可以查看天气预报或者天气App等相关信息渠道。

ZH

今天适合出行吗？



由于我无法获取实时的天气和交通等相关信息，所以我无法直接回答今天是否适合出行。建议您查看当地的天气预报和交通状况，再根据实际情况做出出行决策。同时也请注意出行安全，祝您旅途愉快！



自然语言处理 - ChatGPT

ChatGPT相比于以往预训练语言模型的优点

更高的语言理解能力

更准确的预测能力

更广泛的应用领域

更快的学习速度



知识广博



有条有理



善解人意



交互能力强

ChatGPT 有越来越多的模型相继问世，大家可以进一步学习、分析。