

什么是计算机视觉？

计算机视觉是一门研究如何使机器“看”的科学，更进一步的说，就是指用摄影机和计算机代替人眼对目标进行识别、跟踪和测量等机器视觉的应用。主要用于模拟人类视觉的优越能力和弥补人类视觉的缺陷。

CV 让机器可以看懂图片里的内容



有一个戴着草帽，赤裸上半身的人在放牛
那个人还在打电话



DEFINITION

“Computer vision is concerned with **the automatic extraction, analysis & understanding of useful information** from a single image or a sequence of images. It involves the development of **a theoretical and algorithmic basis** to achieve automatic visual understanding.”



Attributed to The British Machine Vision Association and Society for Pattern Recognition

计算机视觉的原理是什么？

目前主流的基于深度学习的机器视觉方法，其原理跟人类大脑工作的原理比较相似。

人类的视觉原理如下：从原始信号**摄入**开始（瞳孔摄入像素 Pixels），接着做**初步处理**（大脑皮层某些细胞发现边缘和方向），然后**抽象**（大脑判定，眼前的物体的形状，是圆形的），然后**进一步抽象**（大脑进一步判定该物体是只气球）。

机器的方法也是类似：构造**多层**的神经网络，较**低层**的识别初级的**图像特征**，若干底层特征组成**更上一层特征**，最终通过**多个层级的组合**，最终在顶层做出**分类**。





计算机视觉的任务综述

• 图像分类




- 图像分类是计算机视觉中重要的基础问题。后面提到的其他任务也是以它为基础
- 卷积神经网络CNNs
- 对应有没有问题？有的话，给出属于某类**概率**

• 目标检测

- 目标检测任务的目标是给定一张图像或是一个视频帧，让计算机找出其中所有目标的位置，并给出每个目标的具体类别
- 区域卷积神经网络R-CNN系列
- 对应目标在哪儿问题？用矩形**框框出目标**

• 图像分割

- **语义分割**试图在语义上理解图像中每个像素是什么；**实例分割**将不同类型的实例进行分类
- 全卷积神经网络FCN
- 对应每个像素的类别问题，用不同颜色画出图像中所有类别的区域轮廓



计算机视觉的任务综述

- **视频分类**
 - 与图像分类不同的是，分类的对象不再是静止的图像，而是一个由多帧图像构成的、包含语音数据、包含运动信息等的视频对象，因此理解视频需要获得更多的上下文信息，不仅要理解每帧图像是什么、包含什么，还需要结合不同帧，知道上下文的关联信息
- **人体关键点检测**
 - 人体关键点检测，通过人体关键节点的组合和追踪来识别人的运动和行为，对于描述人体姿态，预测人体行为至关重要。在 Xbox 中就有利用到这个技术
- **场景文字识别**
 - 场景文字识别是在图像背景复杂、分辨率低下、字体多样、分布随意等情况下，将图像信息转化为文字序列的过程。停车场、收费站的车牌识别就是典型的应用场景
- **目标跟踪**
 - 目标跟踪，是指在特定场景跟踪某一个或多个特定感兴趣对象的过程。传统的应用就是视频和真实世界的交互，在检测到初始对象之后进行观察。无人驾驶里就会用到这个技术






分类与检测



图像分类 (Image Classification)

需要判断出图像（或图像中的目标）所属的类别，即基于给定一个图片输出图片中的类别。如左图所示，假如在学习分类中数据集有人（person）、羊（sheep）、狗（dog）和猫（cat）四种，则该图像中含有person、sheep和dog三种类别。


KNN算法



KNN算法的优势

1. 易于估计结果
2. 算法容易实现
3. 在样本足够大的时候，能够有比较高的精度
4. 算法实现能够并行化

参考http://blog.sina.com.cn/s/blog_802a94a20102vj70.html




KNN算法的劣势

1. 数据储存量大（需要储存训练集中所有的样本）
2. 在预测时计算量大（需要计算到所有样本点的距离）
3. 容易对维度灾难敏感

K-means算法


K-means的实现过程大致表示如下：

- (1) 随机选取K个初始聚类中心；
- (2) 计算每个样本到各聚类中心的距离，将每个样本归到其距离最近的聚类中心；
- (3) 对每个簇，以所有样本的均值作为该簇新的聚类中心；
- (4) 重复第(2)~(3)步，直到聚类中心不再变化或达到设定的迭代次数。



AlexNet

2012年，Alex Krizhevsky 发表了 Alexnet（参见：ImageNet Classification with Deep Convolutional Neural Networks），它是 LeNet 的一种更深更宽的版本，并以显著优势赢得了困难的 ImageNet 竞赛。



AlexNet其实就是一个简单的架构，其中的卷积层和聚积层相互叠加，最顶部的是全连接层。而AlexNet率先使用GPU，将训练的速度提高了十倍以上。

虽然AlexNet现在有些过时，但它仍然是运用神经网络完成各种任务的起点。不管是完成计算机视觉任务，还是语音识别任务，很多模型都是在AlexNet模型的框架和思想上改良的。

参考<https://blog.csdn.net/maxiao1204/article/details/65653781>

AlexNet 特点总结

AlexNet 将 LeNet 的思想扩展到了更大的能学习到远远更复杂的对象与对象层次的神经网络上。这项工作的贡献有：


- 使用修正的线性单元（ReLU）作为非线性函数。
- 在训练的时候使用 Dropout 技术有选择地忽视单个神经元，以避免模型过拟合。
- 覆盖进行最大池化，避免平均池化的平均化效果。
- 使用 GPU NVIDIA GTX 580 减少训练时间。在那时，GPU 相比 CPU 可以提供更多数量的核，训练时间可以提升 10 倍，这又反过来允许使用更大的数据集和更大的图像。
- AlexNet 的惊艳表现，让深度学习再次受到广泛关注。

目标检测 (object detection)

不仅需要识别出图片中有哪些类别，而且需要用矩形框将它们进行准确定位（如右图所示）。相比于图像分类，目标检测增加了定位这一新的任务。

由于分类和检测有较高的相关性，我们将分类和检测领域的经典方法进行归纳说明。

参考<https://www.cnblogs.com/augustone/p/10533132.html>



R-CNN

R-CNN 是将 CNN 用于物体检测的早期应用。该论文首次展示出：与更简单的、基于 HOG 特征的其他系统相比，CNN 在 PASCAL VOC 上有非常优越的物体识别表现。现在，我们来看一看它们的架构Regions With CNNs (R-CNN) 是如何工作的。

R-CNN 的目标是：导入一张图片，通过方框正确识别物体以及它的位置。

输入： 图像

输出： 方框+每个物体的标签

但怎么知道这些方框应该在哪里呢？R-CNN 的处理方式——在图像中搞出一大堆方框，看看是否有任何一个与某个物体重叠。

参考<https://www.leiphone.com/news/201704/GEJU2kNeqGDpizN2.html>

2014: R-CNN





Figure 2: Two examples of our selective search showing the necessity of different scales. On the left we find many objects at different scales. On the right we necessarily find the objects at different scales as the girl is contained by the tv.

R-CNN

生成这些边框、或者说是推荐局域，R-CNN 采用的是一项名为 Selective Search 的流程。在高层级，Selective Search 通过不同尺寸的窗口来查看图像。对于每一个尺寸，它通过纹理、色彩或密度把相邻像素划为一组，来进行物体识别。当边框方案生成之后，R-CNN 把选取区域变形为标准的方形，并将之“喂”给改良版的 AlexNet（ImageNet 2012 的冠军方案，它启发了 R-CNN）。

在 CNN 的最后一层，R-CNN 加入了一个支持向量机，它要做的事很简单：判断是否是一个目标物体并进行分类。这便是右图中的第四步。



对边框进行改进

现在，既然已经找到了方框中的物体，我们是否能缩小边框，让它更符合物体的三维尺寸？

答案是肯定的，这是 R-CNN 的最后一步。R-CNN 在推荐区域上运行一个简单的线性回归，生成更紧的边框坐标以得到最终结果。

该回归

模型的输入和输出

输入：对应物体的图像子区域

输出：针对该物体的新边框系统

模型步骤总结

- 生成对边框的推荐
- 在预训练的 AlexNet 上运行方框里的物体。用支持向量机来看边框里的物体是什么。
- 在线性回归模型上运行该边框，在物体分类之后输出更紧的边框的坐标。

Fast R-CNN

R-CNN 的效果非常好，但出于以下几个原因，它运行起来特别慢：

对于每一个图像的每一个推荐区域，它都需要一个 CNN (AlexNet) 的 forward pass。这意味着每个图像就需要约 2000 个 forward pass。

它必须训练三个不同的模型——生成图像特征的 CNN，预测类别的分类器以及收紧边框的回归模型。这使得训练流水线变得特别困难。

在 2015 年，R-CNN 的第一作者 Ross Girshick 提出了 Fast R-CNN 模型解决了上述两个问题，它加速和简化了 R-CNN。




Ross Girshick

Fast R-CNN

Fast R-CNN 特性

对于 CNN 的 forward pass, Ross 意识到对于每个图像, 许多推荐区域会不可避免的重叠, 同样的 CNN 运算会被重复多次 (约2000 次)。他的思路很简单: 为什么不能在每一个图像上只运行一次 CNN, 并找到一种在 2000 个推荐里共享计算的方式?

借助名为 RoI (Region of Interest) Pooling 的技术, Fast R-CNN 实现了该思路。原始图像只需要计算一遍, 而不是 2000 遍。Fast R-CNN将整张图像归一化后直接送入CNN, 在最后的卷积层输出的feature map上, 加入建议框信息, 使得在此之前的CNN运算得以共享。



参考https://www.sohu.com/a/137117448_297710

Fast R-CNN

第二项特性是在一个模型里联合训练 CNN、分类器和边框回归量。而此前，提取图像特征要用 CNN，分类要用支持向量机，收紧边框要用回归。Fast R-CNN 用一个单个的网络完成这三项任务。至于这是如何实现的，请看右图。Fast R-CNN 在 CNN 之上添加一个 softmax 层输出分类，来代替支持向量机。


添加一个与 softmax 平行的线性回归层，来输出边框坐标。这种方式，所有需要的输出都通过单个神经网络得到。

这是模型整体的输入和输出：

输入：有区域推荐的图像

输出：每个区域的物体识别，收紧的边框

2. 把不同模型整合为一个网络



Faster R-CNN

即便有众多优点，Fast R-CNN 仍然有一个重大瓶颈：选区推荐器。正如我们看到的，检测物体位置的第一步，是生成一系列候选边框来进行测试。在 Fast R-CNN 里，这些推荐通过 Selective Search 生成。这是一个相当慢的过程，成为系统整体的瓶颈。

在 2015 年，微软的孙剑、任少卿、何凯明、Ross Girshick 找到了一个让推荐步骤几乎不需要成本的办法，这通过被他们称之为 Faster R-CNN 的架构来实现，它加速了选区推荐。

Faster R-CNN是2015年提出的第一个真正意义上的端到端的深度学习检测算法，其最大的创新之处就在于通过添加RPN网络，基于Anchor机制来生成候选框（代替selective search），最终将特征提取、候选框选取、边框回归和分类都整合到一个网络中，从而有效地提高检测精度和检测效率。



孙剑

参考https://www.sohu.com/a/137117448_297710

Faster R-CNN


Faster R-CNN 背后的思路是：既然选区推荐取决于 CNN forward pass 已经计算出来的图像特征。那么，为什么不对区域推荐重复利用这些 CNN 结果，来代替运行一个单独的 selective search 算法？这便是 Faster R-CNN 更快的原因。

右图中，你可以看到单个 CNN 是如何同时进行选区推荐和分类的。利用这种方式，只有一个 CNN 需要被训练，我们也几乎免费得到了选区推荐。

这是模型的输入和输出：

输入： 图像（选区推荐并不需要）

输出： 分类、图中物体的边框坐标



Faster R-CNN

选区是如何生成的？Faster R-CNN 在 CNN 特征之上添加了完全卷积网络（Fully Convolutional Network），以生成 Region Proposal Network。



Region Proposal Network 通过在 CNN 特征图上传递滑窗（sliding window）来运作，在每个窗口输出 K 潜在边框和对每个边框的评估分值。这些 K 边框代表了什么呢？

直觉上，我们知道图像中的物体应该符合特定的常用长宽比例和尺寸，比如类似于人体形状的矩形选框。类似的，我们知道很窄的选框并不会太多。于是我们创造出 anchor boxes —— K 常用长宽比例，对于每一个 anchor box，我们输出选框以及图像中的每个位置的分值。有了这些 anchor boxes，我们看看 Region Proposal Network 的输入、输出。

输入：CNN 特征图

输出：每个 anchor 对应一个选框。一个分值，用来表示选框内图像是否为物体。之后把每个可能是物体的选框导入 Fast R-CNN，生成分类和收紧的选框。

参考https://blog.csdn.net/weixin_34362790/article/details/90419340





图像分割

图像分割

图像分割就是预测图像中每一个像素所属的类别或者物体。

图像分割有两个子问题:

- 1.只预测类别层面的分割，对每个像素标出一个位置。
- 2.区分不同物体的个体。

普通分割将不同像素区域分开，如前景与背景分割开（狗的区域、猫的区域与背景分割开）。**语义分割**在普通分割的基础上，分类出每一块区域的语义（即这块区域是什么物体），如把画面中的所有物体都指出它们各自的类别。**实例分割**在语义分割的基础上，给每个物体编号，如这个是该图像中的狗A，那个是该图像中的狗B。

参考https://blog.csdn.net/xiangz_csdn/article/details/79303497

什么是图像分割



预测图像中每一个像素所属的类别或者物体

FCN

FCN是第一个成功使用深度学习做图像语义分割的模型。主要贡献有两点：


提出了全卷积网络：将全连接网络替换成了卷积网络，使得网络可以接受任意大小的图片，并输出和原图一样大小的分割图。只有这样，才能为每个像素做分类。

使用了反卷积层 (Deconvolution)：分类神经网络的特征图一般只有原图的几分之一大小。想要映射回原图大小必须对特征图进行上采样，这就是反卷积层的作用。虽然名字叫反卷积层，但其实它并不是卷积的逆操作，更合适的名字叫做转置卷积 (Transposed Convolution)，作用是从小的特征图卷出大的特征图。

作者的FCN主要使用了三种技术：

- (1) 不含全连接层(fc)的全卷积(fully conv)网络，可适应任意尺寸的输入。
- (2) 增大数据尺寸的反卷积(deconv)层，能够输出精细的结果。
- (3) 结合不同深度层结果的跳级(skip)结构，同时确保鲁棒性和精确性。

参考<https://blog.csdn.net/lz739337660/article/details/88990259>



回想一下针对分类的卷积神经网络知识：

分类使用的网络通常会在最后连接几层全连接层，它会将原来二维的矩阵（图片）压扁成一维的，从而丢失了空间信息，最后训练输出一个标量，这就是我们的分类标签。

而图像语义分割的输出需要是分割图，且不论尺寸大小，但是至少是二维的。所以，我们需要丢弃全连接层，换上全卷积层，而这也就是全卷积网络了。

FCN



卷积化

卷积化即是将普通的分类网络（比如VGG16，ResNet50/101等网络）丢弃全连接层，换上对应的卷积层即可。

上采样

这里的上采样即是反卷积Deconvolution。（注：关于这个名字不同框架不同，Caffe和Kera里叫Deconvolution，而tensorflow里叫conv_transpose）。普通的池化会缩小图片的尺寸，比如VGG16 五次池化后图片被缩小了32倍。为了得到和原图等大的分割图，我们需要上采样/反卷积，如右图所示。

参考<https://www.cnblogs.com/xiaoming123abc/p/5883927.html>



FCN

跳跃结构(忽略连接结构)

这个结构的作用就在于优化结果，因为如果将全卷积之后的结果直接上采样得到的结果是很粗糙的，所以作者将不同池化层的结果进行上采样之后来优化输出,如右上图所示。不同上采样结构得到的结果如右下图所示。


这是深度学习应用于图像语义分割的开山之作，所以得了CVPR2015的最佳论文。但是，还是有一些处理比较粗糙的地方，如下：

得到的结果还是不够精细。进行8倍上采样虽然比32倍的效果好了很多，但是上采样的结果还是比较模糊和平滑，对图像中的细节不敏感。



对各个像素进行分类，没有充分考虑像素与像素之间的关系。忽略了在通常的基于像素分类的分割方法中使用的空间规整（spatial regularization）步骤，缺乏空间一致性。

使用了较浅层的特征，因为fuse操作会加上较上层的pool特征值，**导致高维特征不能很好得以使用**。同时也因为使用较上层的pool特征值，导致**FCN对图像大小变化有所要求**，如果测试集的图像远大于或小于训练集的图像，FCN的效果就会变差。


参考<https://www.cnblogs.com/xiaoming123abc/p/5883927.html>



SegNet/DeconvNet



这样的对称结构有种自编码器的感觉在里面，先编码再解码。这样的结构主要使用了反卷积和上池化。即：




反卷积如上。而上池化的实现主要在于池化时记住输出值的位置，在上池化时再将这个值填回原来的位置，其他位置填0即OK。

参考https://blog.csdn.net/weixin_30593261/article/details/97100465


模型的对称结构有种自编码器的感觉在里面，先编码再解码。这样的结构主要使用了反卷积和上池化。反卷积如左图所示，而上池化的实现主要在于池化时记住输出值的位置，在上池化时再将这个值填回原来的位置，其他位置填0即OK。

DeconvNet 和 SegNet 的结构非常类似，只不过 DeconvNet 在encoder和decoder之间使用了FC层作为中继。

记录pooling index，然后扩大空间，再用卷积填充：



Pyramid Scene Parsing Network



Pyramid Scene Parsing Network的核心贡献是Global Pyramid Pooling，翻译成中文叫做全局金字塔池化。它将特征图缩放到几个不同的尺寸，使得特征具有更好的全局和多尺度信息，这一点在准确率提升上非常有用。其实不光是语义分割，金字塔多尺度特征对于各类视觉问题效果都较为显著。

U-Net网络

U-Net网络可以利用较少的数据集进行端到端训练，医学领域应用较多（医学领域的标注数据获取成本很高）：

(1) 为了更有效的利用标注数据，采用数据增强的方法（训练样本进行随机弹性形变）。

(2) 网络由收缩路径获取上下文信息，用对称的扩张路径进行精确定位。


如右图所示，网络结构由contracting path和expansive path组成。

Contracting path:

含有重复结构，每个都有2个3x3卷积层，relu层和2x2最大池化层；每一次下采样都将特征通道数加倍。

Expansive path:

每一步都使用反卷积，每次反卷积后将通道数量减半，特征图大小加倍；反卷积后，将反卷积的结果与contracting path中对应的步骤的特征图拼接起来；对拼接后的map再进行2次3*3卷积；最后一层卷积核大小为1x1，将64通道的特征图转为特定类别数量。



Mask R-CNN

Mask R-CNN是何凯明的又一项经典研究，将Object Detection与Semantic Segmentation合在了一起。它的贡献主要是以下几点。

第一，神经网络有了多个分支输出。Mask R-CNN使用类似Faster R-CNN的框架，Faster R-CNN的输出是物体的bounding box和类别，而Mask R-CNN则多了一个分支，用来预测物体的语义分割图。也就是说神经网络同时学习两项任务，可以互相促进。

第二，在语义分割中使用Binary Mask。原来的语义分割预测类别需要使用0 1 2 3 4等数字代表各个类别。在Mask R-CNN中，检测分支会预测类别。这时候分割只需要用0 1预测这个物体的形状Mask就行了。

第三，Mask R-CNN提出了RoIAlign用来替换Faster R-CNN中的RoIPooling。RoIPooling的思想是将输入图像中任意一块区域对应到神经网络特征图中的对应区域。RoIPooling使用了化整的近似来寻找对应区域，导致对应关系与实际情况有偏移。这个偏移在分类任务中可以容忍，但对于精细度更高的分割则影响较大。为了解决这个问题，RoIAlign不再使用化整操作，而是使用线性插值来寻找更精准的对应该区域。效果就是可以得到更好地对应。实验也证明了效果不错。右图展示了与之前方法的对比，下面的图是Mask R-CNN，可以看出精细了很多。

参考<https://blog.csdn.net/GreenHandCGL/article/details/88050274>

