



受限（限制）玻尔兹曼机

主讲人：吴昊

受限波尔兹曼机

与传统的浅层机器学习模型相比，以深度卷积神经网络为代表的深度学习模型具有非常鲁棒的特征提取能力。随着分布式计算平台的发展，数据处理能力极大地得以提升，在图像识别，语音识别，自然语言处理等领域，取得了比传统机器学习更为优越的成果。


除此之外，以RBM（受限玻尔兹曼机）为基础模型的深度学习技术和推荐系统相结合也成为了一个热点。智能推荐系统本质上是从一堆看似杂乱无章的原始流水数据中，抽象出用户的兴趣因子，挖掘出用户的偏好，有非常好的实际应用价值。例如大众点评、美团等。

从严格意义上说，RBM并不属于深层神经网络，它只是一个两层结构，并不“深”，但它同时也是构成其它深度神经网络的常用层次组件。因此，理解如何把RBM应用到推荐系统上，将有助于理解更复杂的深度学习算法的应用。



受限波尔兹曼机


受限波尔兹曼机(Restricted Boltzmann Machine, 简称RBM)是由Hinton等于1986年提出的一种生成式随机神经网络 (generative stochastic neural network)。如右图所示, 该网络由一些可见单元(visible unit, 对应可见变量, 亦即数据样本)和一些隐藏单元(hidden unit, 对应隐藏变量)构成, 可见变量和隐藏变量都是二元变量, 亦即其状态取 $\{0,1\}$ 。



受限波尔兹曼机

模型图如右图所示，每一层的节点之间没有链接，一层是可视层，即输入数据层(v)，一层是隐藏层(h)，当输入v的时候，通过 $p(h|v)$ 可以得到隐藏层h，而得到隐藏层h之后，通过 $p(v|h)$ 又能得到可视层。通过调整参数，若使得从隐藏层得到的可视层v1与原来的可视层v一样，那么得到的隐藏层就是可视层另外一种表达，因此隐藏层可以作为可视层输入数据的特征，所以它就是一种深度学习方法。

参考<https://www.cnblogs.com/kemaswill/p/3203605.html>



Restricted: No interaction between hidden variables

Inferring the distribution over the hidden variables is easy:

$$P(\mathbf{h}|\mathbf{v}) = \prod_j P(h_j|\mathbf{v}) \quad P(h_j = 1|\mathbf{v}) = \frac{1}{1 + \exp(-\sum_i W_{ij}v_i - a_j)}$$

Factorizes: Easy to compute

Similarly:


$$P(\mathbf{v}|\mathbf{h}) = \prod_i P(v_i|\mathbf{h}) \quad P(v_i = 1|\mathbf{h}) = \frac{1}{1 + \exp(-\sum_j W_{ij}h_j - b_i)}$$

Markov random fields, Boltzmann machines, log-linear models.

受限波尔兹曼机


受限玻尔兹曼机是一种基于能量模型的神经网络架构，虽然不像通常的卷积神经网络一样被人熟知，但近年来在推荐系统中受到了越来越多的关注，在协同过滤推荐等领域表现出越来越重要的作用。

最典型的受限玻尔兹曼机如右图所示，在两层简单的结构中包含分布式的输入的可见层和隐含层结构。



受限波尔兹曼机

和通常的前馈神经网络不同的是，受限波尔兹曼机可以通过可见层的状态预测对应隐含层的状态，相反亦可以由隐含层预测可见层对应单元的状态。同时，它与波尔兹曼机的不同在于同一层内的单元之间没有相互连接。



波尔兹曼机(左)与受限波尔兹曼机(右)的区别

受限波尔兹曼机学习目标


1. RBM的学习目标-最大化似然(Maximizing likelihood)

RBM是一种基于能量(Energy-based)的模型, 其可见变量 v 和隐藏变量 h 的联合配置(joint configuration)的能量为:

$$E(\mathbf{v}, \mathbf{h}; \theta) = - \sum_{ij} W_{ij} v_i h_j - \sum_i b_i v_i - \sum_j a_j h_j$$

其中 θ 是RBM的参数 $\{W, a, b\}$, W 为可见单元和隐藏单元之间的边的权重, b 和 a 分别为可见单元和隐藏单元的偏置(bias)。

有了 v 和 h 的联合配置的能量之后, 我们就可以得到 v 和 h 的联合概率。
RBM是一种典型的概率模型, 模型中的状态通过概率来表示。在每一个时间点上受限波尔兹曼机的状态由可见层和隐含层单元决定, 其可被观测到的状态可由联合概率分布来表示。



受限波尔兹曼机学习目标

$$P_{\theta}(\mathbf{v}, \mathbf{h}) = \frac{1}{Z(\theta)} \exp(-E(\mathbf{v}, \mathbf{h}; \theta))$$

其中 $Z(\theta)$ 是归一化因子，也称为配分函数 (partition function)，用于表示系统所有可能的状态。其中 p 为可见层和隐藏层的联合概率分布函数。这一联合概率分布在物理上就是著名的玻尔兹曼分布——在给定能量 E 上粒子在某个状态上被观测到的概率。

根据前面能量等式，可以将上式写为：

$$P_{\theta}(\mathbf{v}, \mathbf{h}) = \frac{1}{Z(\theta)} \exp \left(\sum_{i=1}^D \sum_{j=1}^F W_{ij} v_i h_j + \sum_{i=1}^D v_i b_i + \sum_{j=1}^F h_j a_j \right)$$

我们希望最大化观测数据的似然函数 $P(\mathbf{v})$ ， $P(\mathbf{v})$ 可由上一等式中 $P(\mathbf{v}, \mathbf{h})$ 对 $\mathbf{h}$ 的边缘分布得到：

$$P_{\theta}(\mathbf{v}) = \frac{1}{Z(\theta)} \sum_{\mathbf{h}} \exp \left[\mathbf{v}^T \mathbf{W} \mathbf{h} + \mathbf{a}^T \mathbf{h} + \mathbf{b}^T \mathbf{v} \right]$$

我们通过最大化 $P(\mathbf{v})$ 来得到RBM的参数，最大化 $P(\mathbf{v})$ 等同于最大化如下式子中的 $L(\theta)$ ：

$$L(\theta) = \frac{1}{N} \sum_{n=1}^N \log P_{\theta}(\mathbf{v}^{(n)})$$

受限波尔兹曼机应用

RBM本质上是一个编码解码器，具体来说，通过RBM我们可以把原始输入数据从可视层映射到隐藏层，得到原始输入数据的隐因子（latent factor）向量表示，这一过程也称为编码过程。然后利用得到的隐藏层向量重新映射回可视层，得到新的可视层数据，这个过程称为解码过程，我们的目标是让解码后的结果能和原始数据尽量接近。

正是利用了上述的原理，在解码的过程中（物品推荐系统），我们不但能得到已评分物品的新评分数据，还能对未评分物品的得分进行预测，这些未评分物品的分数排序可以形成推荐列表。



受限波尔兹曼机应用

基于RBM的协同过滤系统

在推荐系统中RBM常常被用于识别数据的隐含因素。例如在电影推荐系统中，人们常常将不同的电影按照不同的潜在变量进行分析，例如不同的电影有动作、科幻、喜剧等潜在信息。模型通过对用户打分数据进行学习，在多个循环后将得出用户的个性化偏好以及用户群体的整体偏好。

在电影推荐的例子中，受限玻尔兹曼机面对的数据是二进制的0/1而不是连续的打分数据。这意味着用于对于电影的评价要么是喜欢（1）要么是不喜欢（0）。这些评价值作为输入层/可见层被送入模型。在给定的数据下，RBM会发掘数据中能提取用户偏好的隐含因素，例如喜好动作类、科幻类电影等等。

如右图所示，电影的评分代表了大众的喜好，但是对于个人而言，需要能够提取用户偏好的隐含因素。



宇宙尽头
豆瓣:9.3



寄生虫
豆瓣:8.7



囍囍老师
豆瓣:7.5



决战中途岛
豆瓣:7.7



致允熙
豆瓣:8.1



小萝莉的猴神大叔
豆瓣:8.4



魔女
豆瓣:7.6




致我的陌生恋人
豆瓣:7.5

受限波尔兹曼机应用

右图中是一个用户对于几部电影评分的简单例子，其中霍比特人由于用户没有评分，数据中使用-1来标注。由于电影的数量庞大，某个用户只对小部分电影进行了评价，需要告诉模型哪些是没有用户评价的输入从而可以忽略这些因素的影响。


图中就对应了给定可见层状态，求出隐含层单元激活概率的情况。可以看出只有Fantasy类型是被激活的，在给定用户评分的情况下，RBM正确地识别出这一用户喜欢的类型更多的偏向于科幻电影。



受限波尔兹曼机应用

在另一种情况下，在知道了用户的偏好后(hidden)，如果要为用户推荐电影(visible)就可以利用已知隐含层求得可见层单元被激活的条件概率，从而为用户推荐偏好类型的电影。

右图中可以看到，RBM计算出被激活的电影除了输入数据中指环王和哈利波特，还为用户推荐了原来没有看过的霍比特人。模型认为喜欢科幻的用户很有可能也喜欢霍比特人。



受限波尔兹曼机应用

前一页图中，网络成功地识别出奇幻为用户偏爱的电影类型，并预测用户会喜欢《霍比特人》。

总结一下，从训练到预测的全过程如下：

- 基于所有用户的数据训练网络；
- 在推理时刻，获取某个特定用户的训练数据；
- 基于这一数据得出激活的隐藏神经元
- 基于隐藏神经元的值得出激活的输入神经元；
- 输入神经元的新值显示了用户将对没看过的电影作出的评价。



深度置信网络


深度置信网络（Deep Belief Nets, DBN）是神经网络的一种。既可以用于非监督学习，类似于一个自编码器；也可以用于监督学习，作为分类器来使用。

从非监督学习来讲，其目的是尽可能地保留原始特征的特点，同时降低特征的维度。从监督学习来讲，其目的在于使得分类错误率尽可能地小。而不论是监督学习还是非监督学习，DBN的本质都是Feature Learning的过程，即如何得到更好的特征表达。

一个DBN模型由若干个RBM堆叠而成，训练过程由低到高逐层进行训练。右下图，以3层隐藏层结构的DBN-DNN为例，网络一共由3个受限玻尔兹曼机（RBM，Restricted Boltzmann Machine）单元堆叠而成，其中RBM一共有两层，上层为隐层，下层为显层。堆叠成DNN的时候，前一个RBM的输出层（隐层）作为下一个RBM单元的输入层（显层）。依次堆叠，便构成了基本的DBN结构，最后再添加一层输出层，就是最终的DBN-DNN结构。

回想一下RBM，由可见层、隐层组成，可见单元用于接受输入，隐含单元用于提取特征。因此隐含单元也有个别名，叫特征检测器。也就是说，通过RBM训练之后，可以得到输入数据的特征。另外，RBM还通过学习将数据表示成概率模型，一旦模型通过无监督学习被训练或收敛到一个稳定的状态，它还可以被用于生成新数据。

参考https://blog.csdn.net/zhanglu_wind/article/details/78949020



深度置信网络

正是由于RBM的以上特点，使得DBN逐层进行训练变得有效，通过隐层提取特征使后面层次的训练数据更加有代表性，通过可生成新数据能解决样本量不足的问题。逐层的训练过程如下：

- 最底部RBM以原始输入数据进行训练；
- 将底部RBM抽取的特征作为顶部RBM的输入继续训练；
- 重复这个过程训练以尽可能多的RBM层。

Hinton提出，这种预训练过程是一种无监督的逐层预训练的通用技术。也就是说，不是只有RBM可以堆叠成一个深度网络，其它类型的网络也可以使用相同的方法来生成网络。