



基于大模型和GaussDB的智能总结

BEIJING NORMAL UNIVERSITY

汇报人：杨博文

小组成员：杨博文、张瑾然、宋雨璇、周欣源



目录

Contents

01 智能视频信息总结

02 数据库的构建

03 查询的构建

Part 1

智能视频信息总结

- 大模型的调用
- 视频信息->文本信息
- 文本信息的切割与录入



Part1 大模型的调用

如何调用大模型



从视频到文字



以文字进模型

我们发现现在的大模型几乎不能处理视频或者能力极弱，所以我们将处理视频的任务转换为处理文字的任务

将课程视频通过语音识别功能转换为文字，作为主要输入内容。然后对文字进行适当处理。

模型生成视频摘要，包括课程重点，结果保存至本地表格中。



Part1 视频信息->文本信息



说话人 (00:00:16): 大家好, 这一节我们讲讲大数据及其特征。随着计算和通信技术、特别是无线移动通信技术的飞速发展。以博客, 微博, 社交网络为代表的新型信息发布方式的不断涌现, 以及云计算, 物联网等技术的兴起, 数据正以前所未有的速度在不断的增长和积累, 大数据时代已经来临。^[1]

说话人 (00:00:43): 大数据的大是相对而言的, 是指数据规模巨大到无法通过当前主流技术工具以可接受的质量完成数据的存储、处理、传输、管理或分析, 需要研究新的相关关键技术。目前, 典型大数据应用当中的数据与传统技术面对的数据显著不同, 体现出一些独有的特征。^[2]

说话人 (00:01:11): 第一个特征是数据量大, 当今事件需要进行及时处理以及提取有用信息的数据, 数量级已经从 TB 级跃升到 PB 乃至 EB 级。第二个特征是数据类型多样大数据的挑战不仅是数据量的大, 也体现在数据类型的多样化。除了普通关系型数据, 还有网络日志、位置相关信息等半结构化数据以及音频, 视频, 图片, 图形等非结构化数据。很多大数据应用以半结构化数据或非结构化数据为中心。^[3]

说话人 (00:01:53): 第三个特征是数据产生和需要处理的速度快。许多大数据应用中, 数据高度动态随着时间快速变化, 比如说这个股票的价格、拍卖的竞价, 还有检测数据都是短暂有效的, 也就是只能在一定的时间范围内有效, 过时则对决策或推导没有意义。另一方面, 应用活动有很强时间要求, 需要对数据处理的速度快。如果移动客户发出的股票交易事务不能在截止期内完成, 便会造成经济以及财经机遇的严重损失。移动电子医疗系统中事务超截止期会导致人员生命的损失。^[4]



视频
信息




文本
信息



Part1 文本信息切割与录入

ID	Time	Original_text	Summary_text	...
1	00:00:16	大家好,这节课...	介绍大数据及其特征...	...
2	00:00:43	大数据的大是...	大规模数据超出...	...
3	00:01:11	第一个特征是...	数据量巨大, 从TB级...	...
...	...	...	...	...




Part 2

数据库的构建

- 数据库设计——ER模型
- 关系模型



Part2 数据库设计—ER模型





Part2 关系模型

video_id	summary
1	大数据的概念及其四个主要特征：数据量大、数据类型多样、数据处理速度快和价值密度低。重点讲解了大数据技术的发展背景、关键需求（可伸缩性、可靠性和高效性）以及主要技术手段，如分布式存储、NoSQL 和 MapReduce 等。
2	数据库的概念及其广泛应用，强调数据库是存储大量互相关联数据的集合，并详细举例说明了高校管理、应急中心、社交平台、电商、通讯、银行等领域数据库的应用场景。同时讲解了数据库管理系统（DBMS）的作用和意义，指出有效的数据管理对各行各业信息化的重要价值。



Part2 关系模型

video_id	id	time	original_text	summary_text
1	1	00:00:16	大家好，这一节我们讲讲大数据及其特征。随着计算和通信技术、特别是无线移动通信技术的飞速发展。以博客，微博，社交网络为代表的新型信息发布方式的不断涌现，以及云计算，物联网等技术的兴起，数据正以前所未有的速度在不断的增长和积累，大数据时代已经来临。	介绍大数据及其特征，技术发展推动数据高速增长，大数据时代到来。
1	2	00:00:43	大数据的大...	大数据规模超出...
...	...	...	...	...
2	6	00:02:00	技术本质上，社交网络、电子商务等互联网+应用就是大量用户通过网络交互访问平台数据库。又如云平台监测管理系统，依赖数据库保存整个云平台的实时运行状态、各个应用基本信息和状态、服务基本信息和状态、虚拟机运行状态等数据。	说明互联网+应用的本质是用户交互访问数据库，云平台通过数据库实时监控系统与服务运行状态。
...	...	...	...	...

Part 3

智能问答系统构建

- 与DeepSeek的交流
- 系统运行流程



Part3与DeepSeek的交流

案例

用户输入：大数据的特征有几个？都是什么？

用户：生成的 SQL 查询语句：

```
WITH video_ids AS (  
  SELECT id FROM summary_table  
  WHERE summary  
  LIKE '%大数据%' OR summary LIKE '%特征%' )
```

```
SELECT vs.original_text, vs.summary_text  
FROM video_summary_table vs  
JOIN video_ids v ON vs.video_id = v.id  
WHERE vs.original_text LIKE '%大数据%'  
OR vs.original_text LIKE '%特征%'  
OR vs.summary_text LIKE '%大数据%'  
OR vs.summary_text LIKE '%特征%';
```

生成SQL查询语句

你是一个擅长将用户问题转换为SQL语句的数据库助手。请遵循以下流程：

1. 先从用户问题中提取关键词（用英文逗号分隔）。
2. 然后生成一条SQL语句，通过在original_text和summary_text字段中模糊匹配这些关键词（使用LIKE语句）进行检索。
3. SQL语句使用 OR 来连接关键词。

● 以下是数据库的表结构：`{schema_description}`

● 任务详细要求：你应当合理考虑人的口语表达中的各种习惯，避免要求过高导致无法查询到有效结果。

● 提示：由于数据来源是授课视频进行切分，你需要考虑到省略主语的情况，比如在叙述大模型的四个特征时，可能直接说“第四个特征/最后一个特征是：.....”而省略主语，由于summary_table表是对整个视频内容的概括，你获取可以从这里找到一部分主语，并考虑视频的id与vs表中的video_id相同进行查找。如：要问大数据的特征，大数据这个词可能会出现在summary_table中的summary段，特征一词可能出现在另一个表的某个段落。你的查询结果至少应该包含一个文本列，这是为了后续在整理输出时方便进行判断。

● 核心任务：请根据用户提出的问题，用PostgreSQL语法生成一个SQL语句。

● 输出要求：请只返回SQL代码，不要给出其他任何内容，如关键词、解释、各类无关符号等，你的输出应该可以直接进行执行而不需要任何其他操作。

● 用户问题：`"{question}"`



Part3与DeepSeek的交流

案例

- Q：我希望了解数据库管理系统的相关知识，我该看哪个视频，从哪个时间开始看？
- A：根据查询结果，建议您观看 ****视频ID 2****，这是一门系统介绍数据库概念的课程。可以从 ****开头 (00:00:15)**** 开始观看，内容涵盖：
 1. 数据库的定义和基本用途（如应急系统等场景）
 2. 数据类型的多样性（数值、文本、音视频等）
 3. 数据库管理系统（DBMS）的核心作用及主流软件（如Oracle、SQL Server等）若时间有限，可直接跳转至 ****00:04:03**** 学习DBMS的详细定义和功能。视频通过生活化类比（如水库、油库）帮助理解数据库的管理本质，适合初学者建立系统认知。

查询结果优化


用户的问题是：**"{question}"**

数据库返回的查询结果如下：**{query_result}**

请基于数据库返回的结果，进行思考，回答用户的问题。请用简洁自然的中文对用户问题做出回答。



Part3 系统运行流程





感谢聆听！

汇报人：杨博文

小组成员：
杨博文、张瑾然、
宋雨璇、周欣源