

实验 综合应用：基于大模型和 GaussDB 的智能总结

第一组

杨博文、张瑾然、宋雨璇、周欣源

目录

1. 实验目的	1
2. 实验环境	3
3. 实验内容	3
4. 实验数据	3
5. 实验作业	3
6. 实验过程	3
1. 需求分析:	3
2. 数据设计:	4
表一: summary_table.....	4
表二: video_summary_table.....	5
3. 操作说明:	6
(一) 步骤一: 构建视频摘要数据库	6
(1) 工程文件结构说明	6
(2) 数据库连接与表结构设计	6
(3) 导入 summary_table 数据 (每个视频的总览摘要)	7
(4) 导入 video_summary_table 数据 (每段视频的逐段总结)	7
(5) 断开连接, 完成数据准备	8
小结: 通过本步骤, 我们完成了:	8
(二) 步骤二: 调用大模型完成 SQL 生成与问答系统构建	8
(1) 系统模块结构说明	8
(2) 用户提问 → 大模型生成 SQL.....	9
(3) 数据库执行查询	9
(4) 生成自然语言回答	9
(5) 完整交互流程示例:	9
小结: 通过本步骤, 系统实现了:	10
4. 源程序说明:	10
1) 程序一: 程序一说明、详细注释以及截图展示	10
2) 程序二: 程序二说明、详细注释以及截图展示	14
5. 运行结果说明:	18
1) 结果一: 结果一说明及展示.	18
2) 结果二: 结果二说明及展示.	19
示例问题一: 大数据的特征有几个? 都是什么?	19
示例问题二: 我想学习数据库系统, 从哪里开始看?	21

图表目录

图 1	构建数据库工程文件结构	6
图 2	guassDB 中创建数据表	8
图 3	调用大模型工程文件结构	8
图 4	输入问题	10
图 5	调用 deepseek 进行 SQL 查询	10
图 6	查询数据库表回答	10
图 7	程序 1 截图说明	14
图 8	程序 2 截图说明	18
图 9	数据库中创建 summary_table	19
图 10	数据库中创建 video_summary_table	19
图 11	查询结果	20
图 12	最终回答	20
图 13	输入问题-生成 sql 语句-查询结果	21
图 14	自然语言大模型生成中文回答	22
表 1	summary_table 设计	4
表 2	来源 idsum.csv 表	5
表 3	video_summary_table 设计	5
表 4	来源视频 1_summary_output.csv 与 视频 2_summary_output.csv 表	6
表 5	python 主要功能说明	9
图表 1	原始视频数据处理	4

1. 实验目的

- (1) 掌握针对实际需求进行数据库系统建设的能力。
- (2) 提高综合运用所学知识解决实际问题的能力。
- (3) 构建基于大模型和 GaussDB 的智能视频总结师，提升学生的学习体验和效率效果。

2. 实验环境

- (1) 数据库管理系统：GaussDB。
- (2) 应用程序开发环境：anaconda/pycharm/psycopg2。
- (3) 一个或多个大模型。

3. 实验内容

- (1) 基于大模型和 GaussDB 的智能视频总结师，提升学生的学习体验和效率效果。

4. 实验数据

在数字文明演进的历史坐标中，以互联网、人工智能、大数据为核心驱动力的新一代信息技术革命，正以前所未有的深度和广度重构人类社会的生产图景。这场变革不仅重塑了现代社会的运行方式——从产业生态的重构到社会治理的革新，从基础学科研究范式的突破到人文学科知识体系的演进，更深刻改写着人类文明的底层逻辑。作为数字世界的基石型技术，信息通信技术（ICT）的创新发展已成为推动社会经济高质量发展的核心引擎。作为数字基础设施建设的重要参与者，华为公司依托在 ICT 领域二十余载的技术积淀，通过持续战略投入和全栈式创新突破，成功研发了具有里程碑意义的分布式关系型数据库 GaussDB。该产品创新性地融合高可用架构设计、智能运维体系与全栈自主可控技术，构建起高可用、高性能、高安全的运行体系，兼具弹性扩展与智能管理优势，支持灵活部署与平滑迁移。这种面向未来的数据库解决方案，不仅攻克了传统数据库在云化、智能化转型中的技术瓶颈，更为各行业核心系统数字化转型升级构筑了智能可靠的数据基础设施。本学期采用线上线下相结合的方式学习，包含视频 60 段以上。

5. 实验作业

- (1) 调用大模型对课程视频进行总结。
- (2) 把视频总结及结果存入数据库，至少保存两个视频段（视频段老师提供）。
- (3) 能够答复学生相关问题。

6. 实验过程

1. 需求分析：

本实验旨在探索大语言模型在教学视频内容处理中的应用，构建一个从视频内容理解到智能问答服务的自动化系统。整体流程如下：

视频 → 语音识别 → 分段总结 → 存入数据库 → 学生自然语言提问 → 大模型解析意图 → 生成 SQL → 查询内容 → 生成中文回答

本实验的系统需求如下：

- (1) 信息抽取能力：对输入的教学视频文本进行语义理解与摘要提取；
- (2) 数据组织能力：将内容结构化存储于数据库，支持按需访问；
- (3) 自然问答能力：学生可用自然语言提问，大模型解析意图后从数据库中检索答案并生成中文解释；
- (4) 稳定扩展性：系统支持多段问答，便于教学部署。

2. 数据设计：

本实验所使用的数据源为教师提供的两段教学视频，具体信息如下：

视频编号	视频主题	时长	概要
1	大数据技术与特征讲解	4 分 36 秒	涉及大数据定义、关键技术、四个 V 特征等
2	数据库与 DBMS 介绍	5 分 50 秒	涉及数据库概念、DBMS 系统、实际应用案例等

视频处理后完成了如下 csv 格式的表创建：

idsum.csv

视频1_summary_output.csv

视频2_summary_output.csv

图表 1 原始视频数据处理

为支持后续自然语言问答，需对视频内容进行结构化组织，设计如下数据库表：

表一：summary_table

用途：用于存储每个视频整体摘要内容，用于快速定位视频核心主题

字段名	类型	说明
id	INTEGER	视频编号（主键）
summary	TEXT	视频整体内容的简洁总结

表 1 summary_table 设计

➤ 数据来源：idsum.csv

1	id	summary			
2		1 大数据的概念及其四个主要特征：数据量大			
3		2 数据库的概念及其广泛应用，强调数据库是			

➤ 数据示例：

id	summary
1	本视频介绍了大数据的特征及关键处理技术，如 MapReduce、Storm 等。
2	本视频讲解了数据库定义、典型应用场景及主流数据库系统（如 Oracle 等）。

表 2 来源 idsum.csv 表

表二： video_summary_table

用途：存储每个视频按时间段切分后的内容和摘要，作为细粒度知识点的查询依据

字段名	类型	说明
video_id	INT	视频编号，关联 summary_table
id	INT	该视频内的片段编号（主键之一）
time	TIME	视频时间戳，如 00:01:31
original_text	TEXT	该时间段原始讲述内容
summary_text	TEXT	对该时间段内容的摘要

表 3 video_summary_table 设计

数据来源：视频 1_summary_output.csv 与 视频 2_summary_output.csv

1	ID	time	original_text	summary_text					
2		1	0:00:16	大家好，这介绍大数据及其特征，技术发展推动数据高速增长，大数据时代到来。					
3		2	0:00:43	大数据的大数据规模超出传统技术能力，需新技术支持，数据特征显著不同。					
4		3	0:01:11	第一个特征数据量巨大，从TB级提升至PB甚至EB级。					
5		4	0:01:31	第二个特征数据类型多样，涵盖关系型、半结构化及非结构化数据。					
6		5	0:01:53	第三个特征数据变化快且时效性强，处理速度要求高，延迟会带来严重后果。					
7		6	0:02:38	最后一个特征大数据价值高但密度低，需大量数据分析。关键需求包括可伸缩性、可靠性和高效性。					
8		7	0:04:12	在大数据的存储关键技术有计算机集群、分布式文件系统、NoSQL；处理技术包括MapReduce和Storm。					
9		8	0:04:31	再见！ 课程结束，告别。					
10									

1	ID	time	original_text	summary_text					
2		1	0:00:15	大家好，首先介绍数据库的定义和基本含义，说明数据库是包含大量相关联数据的集合。					
3		2	0:00:51	当今世界说明数据库广泛应用于高校管理系统，如学生选课、教师评价等信息的存储。					
4		3	0:01:20	比如应急中介绍应急数据库的应用，包括灾害预测、指挥调度和恢复数据的管理。					
5		4	0:01:34	比如微信、说明社交平台数据库保存用户信息、消息、评论和支付等数据。					
6		5	0:01:52	还有电子商指出电商和云平台数据库支持商品交易和平台运行状态的实时监控。					
7		6	0:02:00	技术本质上说明互联网+应用的本质是用户交互访问数据库，云平台通过数据库实时监控与服务运行状态。					
8		7	0:02:25	又如通讯进一步举例数据库在通讯、银行、企业和交通运输系统中的应用。					
9		8	0:02:52	我们说数据解释数据库中数据类型的多样性，包括数值、文本、图像、音视频等。					
10		9	0:03:12	包含互相关说明数据库形式多样，可纸质存储，也可由各种数据库软件系统管理。					
11		10	0:03:37	咱们这门课明确课程中数据库定义为长期存储、可共享的计算机管理数据集合。					
12		11	0:04:03	我们把这类介绍数据库管理系统（DBMS）的定义及主流软件名称。					
13		12	0:04:34	我们应该注通过水库油库类比，强调数据库不仅是数据集合，更注重管理系统。					
14		13	0:05:01	各行各业的说明 DBMS 通过通用功能支持各行业数据管理，推动信息化。					
15		14	0:05:42	这一节我们总结本节课课程内容，结束语。					

示例数据（视频 1&视频 2）：

video_id	id	time	original_text	summary_text
1	3	00:01:11	第一个特征是数据量大...	数据量巨大，从 TB 级跃升至 PB 级
1	4	00:01:31	第二个特征是数据类型...	涉及结构化、非结构化、半结构化数据
2	2	00:00:51	高校信息系统数据库...	说明数据库在选课系统中的广泛应用
2	4	00:01:34	微信、微博数据库保存了...	说明社交平台数据库保存用户信息和互动记录等

表 4 来源视频 1_summary_output.csv 与 视频 2_summary_output.csv 表

3. 操作说明：

（一）步骤一：构建视频摘要数据库

（1）工程文件结构说明

本项目目录结构如下所示：

名称	修改日期	类型	大小
.idea	2025/5/20 10:02	文件夹	
idsum.csv	2025/5/19 19:13	Microsoft Excel Co...	1 KB
main.py	2025/5/20 9:22	Python.File	2 KB
视频1_summary_output.csv	2025/5/19 19:17	Microsoft Excel Co...	5 KB
视频2_summary_output.csv	2025/5/19 19:20	Microsoft Excel Co...	6 KB

图 1 构建数据库工程文件结构

- main.py：主程序文件，用于创建数据库表结构并导入 CSV 数据
- idsum.csv：存储两个视频的整体总结信息（对应 summary_table）
- 视频 1_summary_output.csv、视频 2_summary_output.csv：每个视频的多段时间节点内容总结（对应 video_summary_table）

（2）数据库连接与表结构设计

使用 Python 中的 psycopg2 包连接 GaussDB 数据库，并创建两个表：

核心源代码如下：

```
conn=psycopg2.connect(database="finance01",user="python01_user28",password="xxx",host="110.41.115.206",port=8000)
```

```
CREATE TABLE summary_table (
id INTEGER PRIMARY KEY,
```

```

summary TEXT
);
CREATE TABLE video_summary_table (
video_id INTEGER,
id INTEGER,
time TIME,
original_text TEXT,
summary_text TEXT,
PRIMARY KEY (video_id, id)
);

```

(3) 导入 summary_table 数据（每个视频的总览摘要）

从 idsum.csv 中读取数据并插入 summary_table 表中：

核心源代码如下：

```

with open('idsum.csv', newline="", encoding='utf-8') as f: reader = csv.DictReader(f)
for row in reader:
cur.execute("INSERT INTO summary_table (id, summary) VALUES (%s, %s) ON
CONFLICT (id) DO NOTHING;", (int(row['id']), row['summary']))

```

(4) 导入 video_summary_table 数据（每段视频的逐段总结）

定义函数 insert_video_summary(), 并分别读取两个 summary_output.csv 文件的数据：

```

python
def insert_video_summary(file_path, video_id):
    with open(file_path, newline="", encoding='utf-8') as f:
        reader = csv.DictReader(f)
        for row in reader:
            cur.execute("""
                INSERT INTO video_summary_table (video_id, id, time,
original_text, summary_text)
                VALUES (%s, %s, %s, %s, %s)
                ON CONFLICT (video_id, id) DO NOTHING;
            """, (
                video_id,
                int(row['ID']),
                row['time'],
                row['original_text'],
                row['summary_text']
            ))

```

执行插入：

```

python
insert_video_summary("视频 1_summary_output.csv", 1)
insert_video_summary("视频 2_summary_output.csv", 2)

```

以下是select * from summary_table;的执行结果集

ⓘ 该表不可编辑。

复制行

复制列

列设置

	id	summary
1	1	大数据的概念及其四个主要特征：数据量大、数据类型多样、数据处理速度快和价值密度低。重点讲解了大数据技术的发展背景、关键需求（可伸缩性、可靠性和高效性）以及主要技术手段，如分布式存储、NoSQL 和 MapReduce 等。
2	2	数据库的概念及其广泛应用，强调数据库是存储大量互相关联数据的集合，并详细举例说明了高校管理、应急中心、社交平台、电商、通讯、银行等领域数据库的应用场景。同时讲解了数据库管理系统（DBMS）的作用和意义，指出有效的

以下是select * from video_summary_table;的执行结果集

ⓘ 该表不可编辑。

复制行

复制列

列设置

	video_id	id	time	original_text	summary_text
1	1	1	00:00:16	大家好，这一节我们讲讲大数据及其特征。随着计算和通信技术、特别是无线移动通信技	介绍大数据及其特征，技术发展推动数据高速增长，大数据时代到来。
2	1	2	00:00:43	大数据的大是相对而言的，是指数据规模巨大到无法通过当前主流技术工具以可接受的质	大数据规模超出传统技术能力，需新技术支持，数据特征显著不同。
3	1	3	00:01:11	第一个特征是数据量大，当今事件需要进行及时处理以及提取有用信息的数据，数量级已	数据量巨大，从TB级提升至PB甚至EB级。

	video_id	id	time	original_text	summary_text
9	2	1	00:00:15	大家好，首先我们说说什么是数据库，数据库都用在哪儿？所谓库，一般只集中存放大量	介绍数据库的定义和基本含义，说明数据库是包含大量相关联数据的集合。
10	2	2	00:00:51	当今世界数据库非常广泛地应用在生产生活的方方面面。比如，高等学校管理信息系统数	说明数据库广泛应用于高校管理系统，如学生选课、教师评价等信息的存储。
11	2	3	00:01:20	比如应急中心数据库，包含地震、洪水、干旱、滑坡、泥石流等突发事件监测防控预测预	介绍应急数据库的应用，包括灾害预测、指挥调度和恢复数据的管理。

图 2 guassDB 中创建数据表

(5) 断开连接，完成数据准备

```
python
cur.close()
conn.close()
```

此时，两个表中的数据均已成功上传，可以配合后续大模型问答系统使用。

小结：通过本步骤，我们完成了：

- ✓ 建立视频数据结构（summary + 分段）
- ✓ 将 CSV 格式的总结数据成功导入数据库
- ✓ 实现主程序 main.py 的模块化与容错插入
- ✓ 后续章节可继续展开 调用大模型 + 用户提问与智能问答过程。

(二) 步骤二：调用大模型完成 SQL 生成与问答系统构建

本步骤基于 DeepSeek 大语言模型，通过自然语言理解与 SQL 自动生成，实现了智能化课程问答系统的核心逻辑：

(1) 系统模块结构说明

名称	修改日期	类型
.idea	2025/5/20 10:02	文件夹
main.py	2025/5/20 9:21	Python 源文件

图 3 调用大模型工程文件结构

模块函数	功能说明
generate_sql_with_deepseek()	接收学生问题，调用大模型生成 SQL 查询语句
query_database()	执行模型生成的 SQL，从数据库中检索结果
generate_natural_answer()	使用大模型对查询结果进行语言组织，生成中文回答
main()	主函数：完成“提问 → SQL → 查询 → 回答”的闭环流程

表 5 python 主要功能说明

(2) 用户提问 → 大模型生成 SQL

系统根据用户输入的自然语言提问，动态生成带模糊匹配的 SQL 语句。

- ✓ 支持关键词提取、LIKE 条件组合
- ✓ 支持模糊搜索 original_text / summary_text / summary 字段
- ✓ 可结合 video_id 实现跨表查找

(3) 数据库执行查询

通过 psycopg2 执行大模型生成的 SQL 并返回结构化结果，例如：

```
[{"original_text": "...", "summary_text": "..."}, {"original_text": "...", "summary_text": "..."}]
```

(4) 生成自然语言回答

系统将查询结果传递给大模型，自动生成中文回答：能实现总结能力（提炼要点）、结构化表达（条理清晰），用于教学问答、个性化解答等。

(5) 完整交互流程示例：

①请输入你的问题（或输入 exit 退出）：

> 大数据的特征有几个？都是什么？

```

Last login: Sat May 24 15:59:59 on ttys000
[yangbowen@Bowen-MacBook-Air 数据库系统大作业 % conda activate WEB
[(WEB) yangbowen@Bowen-MacBook-Air 数据库系统大作业 % cd 核心实现
[(WEB) yangbowen@Bowen-MacBook-Air 核心实现 % python main.py

请输入你的问题（或输入 exit 退出）：
> 大数据的特征有几个？都是什么？

```

图 4 输入问题

②生成 SQL 查询语句并查询结果：

```
核心实现 — python main.py — python — python main.py — 80x24

生成的 SQL 查询语句：
SELECT s.summary
FROM summary_table s
WHERE s.summary LIKE '%大数据%特征%'
OR s.summary LIKE '%大数据%特点%'
OR s.summary LIKE '%大数据%特性%'
OR s.summary LIKE '%大数据%个%'
OR s.summary LIKE '%大数据%哪些%'
OR s.summary LIKE '%大数据%什么%'
OR s.summary LIKE '%大数据%包括%'
OR s.summary LIKE '%大数据%有%'

UNION

SELECT v.original_text || ' ' || v.summary_text
FROM video_summary_table v
JOIN summary_table s ON v.video_id = s.id
WHERE (v.original_text LIKE '%特征%' OR v.summary_text LIKE '%特征%')
AND (v.original_text LIKE '%大数据%' OR v.summary_text LIKE '%大数据%')
AND (v.original_text LIKE '%个%' OR v.summary_text LIKE '%个%' OR v.original_text LIKE '%什么%' OR v.summary_text LIKE '%什么%' OR v.original_text LIKE '%哪些%' OR v.summary_text LIKE '%哪些%')

查询结果：[{'summary': '大数据的概念及其四个主要特征：数据量大、数据类型多样
```

图 5 调用 deepseek 进行 SQL 查询

③ 回答：

大数据的特征包括：数据量大、类型多样、处理速度快、价值密度低（4V 特征）。

回答：大数据的特征主要有四个，通常被称为“4V”：

1. **数据量大 (Volume)**：指海量的数据规模，远超传统数据库处理能力。
2. **数据类型多样 (Variety)**：包含结构化（如表格）、半结构化（如日志）和非结构化数据（如视频、图片）。
3. **处理速度快 (Velocity)**：数据实时生成且时效性强，需快速处理（如股票交易或医疗监测）。
4. **价值密度低 (Value)**：数据中高价值信息稀疏，需聚合分析才能提取（如商业预测）。

这些特征推动了对分布式存储、NoSQL等技术需求，以满足可扩展性、可靠性和高效性。

请输入你的问题（或输入 exit 退出）：

>

图 6 查询数据库表回答

小结：通过本步骤，系统实现了：

- ✓ 无需预设问题模板的自然语言解析
- ✓ 精准生成 SQL 的意图转译能力
- ✓ 教学视频内容的语义问答

4. 源程序说明：

1) 程序一：程序一说明、详细注释以及截图展示

首先，“setup.py”文件成功实现了：在数据库中建立两个数据表 summary_table 以存储每个视频的总览摘要、video_summary_table 以存储每个视频的逐段内容，并模块化

上传两个表的结构化数据，最后我们可视化查询结果验证成功导入。

源代码详细注释如下：

```
import psycopg2 # 用于连接 PostgreSQL 数据库
import csv      # 用于读取 CSV 文件

# 1. 连接数据库
conn = psycopg2.connect(
    database="finance01",      # 数据库名称
    user="python01_user28",    # 用户名
    password="python01_user28@123", # 密码
    host="110.41.115.206",     # 数据库服务器地址
    port=8000                  # 端口号
)
cur = conn.cursor() # 创建游标对象用于执行 SQL 语句

# 2. 创建两个数据表（如不存在则自动创建）
# 表一：summary_table —— 用于存储每个视频的总览摘要
cur.execute("""
    CREATE TABLE IF NOT EXISTS summary_table (
        id INTEGER PRIMARY KEY,      -- 视频编号，主键
        summary TEXT                  -- 视频的整体总结内容
    );
""")

# 表二：video_summary_table —— 存储每个视频的逐段内容
cur.execute("""
    CREATE TABLE IF NOT EXISTS video_summary_table (
        video_id INTEGER,            -- 视频编号，外键
        id INTEGER,                  -- 视频内的段落编号
        time TIME,                   -- 视频时间戳
        original_text TEXT,          -- 视频原始内容
        summary_text TEXT,           -- 视频段落摘要
    );
""")
```

```

        PRIMARY KEY (video_id, id) -- 联合主键，确保唯一性
    );
    """
conn.commit() # 提交表结构更改

# 3. 导入 summary_table 表的数据（整体摘要）
with open('idsum.csv', newline="", encoding='utf-8') as f:
    reader = csv.DictReader(f) # 将 CSV 文件读取为字典形式
    for row in reader:
        cur.execute(
            "INSERT INTO summary_table (id, summary) VALUES (%s, %s) ON
CONFLICT (id) DO NOTHING;",
            (int(row['id']), row['summary']) # 插入数据，如主键冲突则忽略
        )
conn.commit() # 提交数据插入

# 4. 定义函数：导入每个视频分段总结数据
def insert_video_summary(file_path, video_id):
    with open(file_path, newline="", encoding='utf-8') as f:
        reader = csv.DictReader(f)
        for row in reader:
            cur.execute("""
                INSERT INTO video_summary_table (video_id, id, time, original_text,
summary_text)
                VALUES (%s, %s, %s, %s, %s)
                ON CONFLICT (video_id, id) DO NOTHING;
            """, (
                video_id,
                int(row['ID']),
                row['time'],
                row['original_text'],
                row['summary_text']
            ))
    conn.commit() # 每个文件插入完后提交一次

```

5. 执行插入：分别插入两个视频的片段数据

```
insert_video_summary("视频 1_summary_output.csv", 1)
```


```
insert_video_summary("视频 2_summary_output.csv", 2)
```

6. 断开数据库连接

```
cur.close()
```

```
conn.close()
```

源代码截图如下：



```
C:\Users\zxy\Desktop\归档\建立\main.py
1 import psycopg2 # 用于连接 PostgreSQL 数据库
2 import csv      # 用于读取 CSV 文件
3
4 # 1. 连接数据库
5 conn = psycopg2.connect(
6     database="finance01", # 数据库名称
7     user="python01_user28", # 用户名
8     password="python01_user28@123", # 密码
9     host="110.41.115.206", # 数据库服务器地址
10    port=8000 # 端口号
11)
12 cur = conn.cursor() # 创建游标对象用于执行SQL语句
13
14 # 2. 创建两个数据表（如不存在则自动创建）
15 # 表一: summary_table — 用于存储每个视频的总览摘要
16 cur.execute("""
17     CREATE TABLE IF NOT EXISTS summary_table (
18         id INTEGER PRIMARY KEY, -- 视频编号, 主键
19         summary TEXT -- 视频的整体总结内容
20     );
21 """)
22
23 # 表二: video_summary_table — 存储每个视频的逐段内容
24 cur.execute("""
25     CREATE TABLE IF NOT EXISTS video_summary_table (
26         video_id INTEGER, -- 视频编号, 外键
27         id INTEGER, -- 视频内的段落编号
28         time TIME, -- 视频时间戳
29         original_text TEXT, -- 视频原始内容
30         summary_text TEXT, -- 视频段落摘要
31         PRIMARY KEY (video_id, id) -- 联合主键, 确保唯一性
32     );
33 """)
34 conn.commit() # 提交表结构更改
35
36 # 3. 导入 summary_table 表的数据（整体摘要）
37 with open('idsum.csv', newline='', encoding='utf-8') as f:
38     reader = csv.DictReader(f) # 将CSV文件读取为字典形式
39     for row in reader:
```

```

36 # 3. 导入 summary_table 表的数据 (整体摘要)
37 with open('idsum.csv', newline='', encoding='utf-8') as f:
38     reader = csv.DictReader(f) # 将CSV文件读取为字典形式
39     for row in reader:
40         cur.execute(
41             "INSERT INTO summary_table (id, summary) VALUES (%s, %s) ON CONFLICT (id) DO NOTHING;",
42             (int(row['id']), row['summary'])) # 插入数据, 如主键冲突则忽略
43         )
44     conn.commit() # 提交数据插入
45
46 # 4. 定义函数: 导入每个视频分段总结数据
47 def insert_video_summary(file_path, video_id):
48     with open(file_path, newline='', encoding='utf-8') as f:
49         reader = csv.DictReader(f)
50         for row in reader:
51             cur.execute("""
52                 INSERT INTO video_summary_table (video_id, id, time, original_text, summary_text)
53                 VALUES (%s, %s, %s, %s, %s)
54                 ON CONFLICT (video_id, id) DO NOTHING;
55             """, (
56                 video_id,
57                 int(row['ID']),
58                 row['time'],
59                 row['original_text'],
60                 row['summary_text']
61             ))
62     conn.commit() # 每个文件插入完后提交一次
63
64 # 5. 执行插入: 分别插入两个视频的片段数据
65 insert_video_summary("视频1_summary_output.csv", 1)
66 insert_video_summary("视频2_summary_output.csv", 2)
67
68 # 6. 断开数据库连接
69 cur.close()
70 conn.close()

```

图 7 程序 1 截图说明

2) 程序二：程序二说明、详细注释以及截图展示

第二个“核心实现-main.py”程序实现了智能教学视频问答系统的核心引擎：第一，用户输入自然语言提问；第二，DeepSeek 大模型将问题转化为 SQL 查询；第三，程序连接数据库执行 SQL；第四，DeepSeek 根据查询结果生成清晰的中文回答。

源代码详细注释如下：

```

from openai import OpenAI # 调用 DeepSeek API 所需模块 (采用 OpenAI SDK)

import psycopg2           # 连接 PostgreSQL 数据库
import os                 # 用于读取环境变量 (可选)

# 1. 配置大模型参数
DEEPSEEK_API_KEY = "这里应该是你的 API Key" # 替换为你的 DeepSeek API 密
钥
client = OpenAI(api_key=DEEPSEEK_API_KEY, base_url="https://api.deepseek.com")
# 初始化客户端

# 定义数据库的表结构描述, 便于传入模型作为语义参考
SCHEMA_DESCRIPTION = """
表 summary_table(id INTEGER, summary TEXT)
表 video_summary_table(video_id INTEGER, id INTEGER, time TIME, original_text
TEXT, summary_text TEXT)
"""

```

2. 大模型生成 SQL 查询语句

```
def generate_sql_with_deepseek(question: str, schema_description: str) -> str:
```

```
    prompt = f"""
```

你是一个擅长将用户问题转换为 SQL 语句的数据库助手。请遵循以下流程：

1. 先从用户问题中提取关键词（用英文逗号分隔）。

2. 然后生成一条 SQL 语句，通过在 original_text 和 summary_text 字段中模糊匹配这些关键词（使用 LIKE 语句）进行检索。

3. SQL 语句使用 OR 来连接关键词。

以下是数据库的表结构：

```
{schema_description}
```

任务详细要求：你应当合理考虑人的口语表达中的各种习惯，避免要求过高导致无法查询到有效结果。

提示：由于数据来源是授课视频进行切分，你需要考虑到省略主语的情况，比如在叙述大模型的四个特征时，可能直接说“第四个特征/最后一个特征是：……”而省略主语，由于 summary_table 表是对整个视频内容的概括，你获取可以从这里找到一部分主语，并考虑视频的 id 与 vs 表中的 video_id 相同进行查找。如：要问大数据的特征，大数据这个词可能会出现在 summary_table 中的 summary 段，特征一词可能出现在另一个表的某个段落。

提示：如有必要，你也可以考虑从 summary_table（这里的 id 就是后面的 video_id）中先获取 video_summary_table 中的 video_id（这两个是对应的，不是两个表中的 id 对应），然后再在第二个表中搜索。你也可以只在第一个表中进行搜索。

提示：你的查询结果至少应该包含一个文本列，这是为了后续在整理输出时方便进行判断。

核心任务：请根据用户提出的问题，用 PostgreSQL 语法生成一个 SQL 语句。

输出要求：请只返回 SQL 代码，不要给出其他任何内容，如关键词、解释、各类无关符号等，你的输出应该可以直接进行执行而不需要任何其他操作。

```
用户问题: "{question}"
```

```
"""
```

```
    # 请求大模型生成 SQL
```

```
    response = client.chat.completions.create(
```

```
        model="deepseek-chat",
```

```
        messages=[{"role": "user", "content": prompt}],
```

```
        stream=False
```

```
    )
```

```
    return response.choices[0].message.content.strip() # 仅返回 SQL 内容
```

3. 执行 SQL 查询数据库

```
def query_database(sql_query: str):
```

```
    # 连接 PostgreSQL 数据库
```

```

conn = psycopg2.connect(
    database="finance01",
    user="python01_user28",
    password="python01_user28@123",
    host="110.41.115.206",
    port=8000
)
cur = conn.cursor()
cur.execute(sql_query) # 执行 SQL
rows = cur.fetchall() # 获取所有查询结果
columns = [desc[0] for desc in cur.description] # 提取列名
cur.close()
conn.close()
return [dict(zip(columns, row)) for row in rows] # 返回字典列表格式

```

4. 大模型生成自然语言回答

```
def generate_natural_answer(question: str, query_result: list):
```

```
    prompt = f"""
```

```
    用户的问题是: "{question}"
```

```
    数据库返回的查询结果如下:
```

```
{query_result}
```

请基于数据库返回的结果，进行思考，回答用户的问题。请用简洁自然的中文对用户问题做出回答。

```
"""
```

```

    response = client.chat.completions.create(
        model="deepseek-chat",
        messages=[{"role": "user", "content": prompt}],
        stream=False
    )
    return response.choices[0].message.content.strip()

```

5. 主交互循环：接收用户问题 → 调用大模型 → 输出查询与回答

```
def main():
```

```
    while True:
```

```
        question = input("\n🧠 请输入你的问题（或输入 exit 退出）: \n>
```

```
").strip()
```

```
        if question.lower() == "exit":
```

```
            break
```

```
        try:
```

```
            # 步骤一：大模型生成 SQL 查询
```



```
sql = generate_sql_with_deepseek(question, SCHEMA_DESCRIPTION)
print(f"\n📄 生成的 SQL 查询语句: \n{sql}")
```

```
# 步骤二: 执行 SQL 查询数据库
```

```
result = query_database(sql)
print(f"\n📄 查询结果: {result}")
```

```
# 步骤三: 基于结果生成自然语言回答
```

```
answer = generate_natural_answer(question, result)
print(f"\n💬 回答: {answer}\n")
```

```
except Exception as e:
```

```
print("❌ 发生错误: ", e)
```

```
# 6. 执行主函数
```

```
if __name__ == "__main__":
    main()
```

源代码截图如下:

```
1  from openai import OpenAI
2  import psycpg2
3  import os
4
5  #1. 配置
6  DEEPSEEK_API_KEY = "这里应该是你的API Key"
7  client = OpenAI(api_key=DEEPSEEK_API_KEY, base_url="https://api.deepseek.com")
8
9  SCHEMA_DESCRIPTION = """
10 表 summary_table(id INTEGER, summary TEXT)
11 表 video_summary_table(video_id INTEGER, id INTEGER, time TIME, original_text TEXT, summary_text TEXT)
12  """
13
14 #2. 生成SQL
15 def generate_sql_with_deepseek(question: str, schema_description: str) -> str:
16     prompt = f"""
17 你是一个擅长将用户问题转换为SQL语句的数据库助手。请遵循以下流程:
18 1. 先从用户问题中提取关键词 (用英文逗号分隔)。
19 2. 然后生成一条SQL语句, 通过在original_text和summary_text字段中模糊匹配这些关键词 (使用LIKE语句) 进行检索。
20 3. SQL语句使用 OR 来连接关键词。
21 以下是数据库的表结构:
22
23 {schema_description}
24
25 任务详细要求: 你应当合理考虑人的口语表达中的各种习惯, 避免要求过高导致无法查询到有效结果。
26 提示: 由于数据来源是授课视频进行切分, 你需要考虑到省略主语的情况, 比如在叙述大模型的四个特征时, 可能直接说“第四个特征/最后一个特
27 提示: 如有必要, 你也可以考虑从summary_table (这里的id就是后面的vedio_id) 中先获取video_summary_table中的vedio_id (这两个是对
28 提示: 你的查询结果至少应该包含一个文本列, 这是为了后续在整理输出时方便进行判断。
29 核心任务: 请根据用户提出的问题, 用PostgreSQL语法生成一个SQL语句。
30 输出要求: 请只返回SQL代码, 不要给出其他任何内容, 如关键词、解释、各类无关符号等, 你的输出应该可以直接进行执行而不需要任何其他操作
31
32 用户问题: "{question}"
33 """
34     response = client.chat.completions.create(
35         model="deepseek-chat",
36         messages=[{"role": "user", "content": prompt}],
37         stream=False
38     )
39     return response.choices[0].message.content.strip()
```

```

41 #3. 执行SQL
42 def query_database(sql_query: str):
43     conn = psycopg2.connect(database="finance01", user="python01_user28", password="python01_user28@123",
44                             host="110.41.115.206", port=8000)
45     cur = conn.cursor()
46     cur.execute(sql_query)
47     rows = cur.fetchall()
48     columns = [desc[0] for desc in cur.description]
49     cur.close()
50     conn.close()
51     return [dict(zip(columns, row)) for row in rows]
52
53 #4. DS处理结果
54 def generate_natural_answer(question: str, query_result: list):
55     prompt = f"""
56     用户的问题是: "{question}"
57
58     数据库返回的查询结果如下:
59     {query_result}
60
61     请基于数据库返回的结果, 进行思考, 回答用户的问题。请用简洁自然的中文对用户问题做出回答。
62     """
63     response = client.chat.completions.create(
64         model="deepseek-chat",
65         messages=[{"role": "user", "content": prompt}],
66         stream=False
67     )
68     return response.choices[0].message.content.strip()
69
70 #5. 主函数
71 def main():
72     while True:
73         question = input("\n💬 请输入你的问题 (或输入 exit 退出): \n> ").strip()
74         if question.lower() == "exit":
75             break
76
77         try:
78             # 1. 生成 SQL
79             sql = generate_sql_with_deepseek(question, SCHEMA_DESCRIPTION)
80             print(f"\n📄 生成的 SQL 查询语句: \n{sql}")
81
82             # 2. 执行 SQL
83             result = query_database(sql)
84             print(f"\n📋 查询结果: {result}")
85
86             # 3. 用大模型生成自然语言回答
87             answer = generate_natural_answer(question, result)
88             print(f"\n💬 回答: {answer}\n")
89
90         except Exception as e:
91             print("❌ 发生错误: ", e)
92
93 #6. 执行主函数
94 if __name__ == "__main__":
95     main()

```

图 8 程序 2 截图说明

5. 运行结果说明:

1) 结果一: 结果一说明及展示。

最后我们在数据库中建立了两个数据表:

summary_table 存储每个视频的总览摘要;

video_summary_table 存储每个视频的逐段内容以及摘要。

以下是select * from summary_table;的执行结果集

该表不可编辑。

复制行复制列列设置

	id	summary
1	1	大数据的概念及其四个主要特征：数据量大、数据类型多样、数据处理速度快和价值密度低。重点讲解了大数据技术的发展背景、关键需求（可伸缩性、可靠性和高效性）以及主要技术手段，如分布式存储、NoSQL 和 MapReduce 等。
2	2	数据库的概念及其广泛应用，强调数据库是存储大量互相关联数据的集合，并详细举例说明了高校管理、应急中心、社交平台、电商、通讯、银行等领域数据库的应用场景。同时讲解了数据库管理系统（DBMS）的作用和意义，指出有效的

图 9 数据库中创建 summary_table

以下是select * from video_summary_table;的执行结果集

该表不可编辑。

复制行复制列列设置

	video_id	id	time	original_text	summary_text
1	1	1	00:00:16	大家好，这一节我们讲讲大数据及其特征。随着计算和通信技术、特别是无线移动通信技	介绍大数据及其特征，技术发展推动数据高速增长，大数据时代到来。
2	1	2	00:00:43	大数据的大是相对而言的，是指数据规模巨大到无法通过当前主流技术工具以可接受的质	大数据规模超出传统技术能力，需新技术支持，数据特征显著不同。
3	1	3	00:01:11	第一个特征是数据量大，当今事件需要进行及时处理以及提取有用信息的数据，数量级已	数据量巨大，从TB级提升至PB甚至EB级。

	video_id	id	time	original_text	summary_text
9	2	1	00:00:15	大家好，首先我们说说什么是数据库，数据库都用在哪儿？所谓库，一般只集中存放大量	介绍数据库的定义和基本含义，说明数据库是包含大量相关联数据的集合。
10	2	2	00:00:51	当今世界数据库非常广泛地应用在生产生活的方方面面。比如，高等学校管理信息系统数	说明数据库广泛应用于高校管理系统，如学生选课、教师评价等信息的存储。
11	2	3	00:01:20	比如应急中心数据库，包含地震、洪水、干旱、滑坡、泥石流等突发事件监测防控预测预	介绍应急数据库的应用，包括灾害预测、指挥调度和恢复数据的管理。

图 10 数据库中创建 video_summary_table

2) 结果二：结果二说明及展示。

示例问题一：大数据的特征有几个？都是什么？

Step1: 用户输入：
大数据的特征有几个？都是什么？

Step2: 自动生成的 SQL：
WITH video_ids AS (
SELECT id
FROM summary_table
WHERE summary LIKE '%大数据%' OR summary LIKE '%特征%'
)SELECT vs.original_text, vs.summary_textFROM video_summary_table vsJOIN video_ids
v ON vs.video_id = v.idWHERE vs.original_text LIKE '%大数据%' OR vs.summary_text
LIKE '%特征%';

Step3: 查询结果（来自数据库，调用大模型）：

[
{
"original_text": "第一个特征是数据量大……",
"summary_text": "数据量巨大，从 TB 级跃升至 PB 级"
},
...
]

]

```
核心实现 — python main.py — python — python main.py — 80x24

查询结果: [{'summary': '大数据的概念及其四个主要特征: 数据量大、数据类型多样、数据处理速度快和价值密度低。重点讲解了大数据技术的发展背景、关键需求(可伸缩性、可靠性和高效性)以及主要技术手段,如分布式存储、NoSQL 和 MapReduce 等。'}, {'summary': '第二个特征是数据类型多样大数据的挑战不仅是数据量的大,也体现在数据类型的多样化。除了普通关系型数据,还有网络日志、位置相关信息等半结构化数据以及音频,视频,图片,图形等非结构化数据。很多大数据应用以半结构化数据或非结构化数据为中心。数据类型多样,涵盖关系型、半结构化及非结构化数据。'}, {'summary': '第三个特征是数据产生和需要处理的速度快。许多大数据应用中,数据高度动态随着时间快速变化,比如说这个股票的价格、拍卖的竞价,还有检测数据都是短暂有效的,也就是只能在一定的时间范围内有效,过时则对决策或推导没有意义。另一方面,应用活动有很强的时间要求,需要对数据处理的速度快。如果移动客户发出的股票交易事务不能在截止期内完成,便会造成经济以及财经机遇的严重损失。移动电子医疗系统中事务超截止期会导致人员生命的损失。数据变化快且时效性强,处理速度要求高,延迟会带来严重后果。'}, {'summary': '最后一个特征是价值高而密度稀疏。大数据当中可能蕴含极富商业价值的信息,但是价值密度很低,只有将大量数据聚合起来分析,才能借助历史数据预测未来的走势。不同大数据应用当中的这个数据在这四个方面中的一个或多个与传统技术面对的数据表现出显著不同。由于这四个特征的核心词都是以字母 V 开头,所以经常说大数据的特征是四个V,平时我们对大数据的谈论往往并非仅仅指数据本身。通常特别指的是大数据技术。尤其在计算机互联网信息领域,大数据技术的目标是简单,高效,安全的共享大数据、支持大数据应用。为此,大数据技术的关键需求至少:包括第一个方面,可伸缩性,能够有效处理越来越多的数据和越来越多的访问。第二,可靠性,能够容忍实际合理的故障。第三,高效性,能够满足应用对数据处理性能的要求。目前的大数据技术主要涉及存储和处理两方面,利用分布式技术实现对结构化、半结构化和非结构化海量数据可扩展,容错,高可用的存储,利用分布式并行编程模型和计算框架,实现对海量数据的处理和分析。大数据价值高但密度低,需大量数据分
```

图 11 查询结果

Step4 最终回答:

大数据的特征通常被称为“4V”，包括数据量大、类型多样、处理速度快和价值密度低。

```
核心实现 — python main.py — python — python main.py — 80x24

据的谈论往往并非仅仅指数据本身。通常特别指的是大数据技术。尤其在计算机互联网信息领域,大数据技术的目标是简单,高效,安全的共享大数据、支持大数据应用。为此,大数据技术的关键需求至少:包括第一个方面,可伸缩性,能够有效处理越来越多的数据和越来越多的访问。第二,可靠性,能够容忍实际合理的故障。第三,高效性,能够满足应用对数据处理性能的要求。目前的大数据技术主要涉及存储和处理两方面,利用分布式技术实现对结构化、半结构化和非结构化海量数据可扩展,容错,高可用的存储,利用分布式并行编程模型和计算框架,实现对海量数据的处理和分析。大数据价值高但密度低,需大量数据分析。关键需求包括可伸缩性、可靠性和高效性。'}]}

回答: 大数据的特征主要有四个,通常被称为“4V”:

1. **数据量大 (Volume)**: 指海量的数据规模,远超传统数据库处理能力。
2. **数据类型多样 (Variety)**: 包含结构化(如表格)、半结构化(如日志)和非结构化数据(如视频、图片)。
3. **处理速度快 (Velocity)**: 数据实时生成且时效性强,需快速处理(如股票交易或医疗监测)。
4. **价值密度低 (Value)**: 数据中高价值信息稀疏,需聚合分析才能提取(如商业预测)。

这些特征推动了对分布式存储、NoSQL等技术需求,以满足可扩展性、可靠性和高效性。

请输入你的问题(或输入 exit 退出):
> ^[
```

图 12 最终回答

示例问题二：我想学习数据库系统，从哪里开始看？

Step1: 用户输入：


我想学习数据库管理系统的相关知识，从哪里开始看？

Step2: 大模型生成的 SQL 查询语句：

系统通过 `generate_sql_with_deepseek()` 函数，调用 DeepSeek 大模型分析提问，并生成如下 SQL 查询：

```
SELECT vs.video_id, vs.time, vs.original_text, vs.summary_text
FROM video_summary_table vs
JOIN summary_table s ON vs.video_id = s.id
WHERE (vs.original_text LIKE '%数据库%'
OR vs.summary_text LIKE '%数据库%'
OR s.summary LIKE '%数据库%'
OR vs.original_text LIKE '%DBMS%'
OR vs.summary_text LIKE '%DBMS%'
OR s.summary LIKE '%DBMS%'
OR vs.original_text LIKE '%管理%'
OR vs.summary_text LIKE '%管理%'
OR s.summary LIKE '%管理%')
ORDER BY vs.video_id, vs.time;
```

该语句通过模糊匹配关键词“数据库”“DBMS”“管理”，同时结合视频整体 summary 与片段 original_text，确保尽可能全面地覆盖用户想了解的知识。



```
核心实现 — python main.py — python — python main.py — 80x24

请输入你的问题（或输入 exit 退出）：
> 我想听数据库管理系统的相关知识，我应该从哪个视频的哪个时间开始听？

生成的 SQL 查询语句：
SELECT vs.video_id, vs.time, vs.original_text, vs.summary_text
FROM video_summary_table vs
JOIN summary_table s ON vs.video_id = s.id
WHERE (vs.original_text LIKE '%数据库管理系统%' OR vs.summary_text LIKE '%数据库
管理系统%' OR s.summary LIKE '%数据库管理系统%')
OR (vs.original_text LIKE '%DBMS%' OR vs.summary_text LIKE '%DBMS%' OR s.summary
LIKE '%DBMS%')
ORDER BY vs.video_id, vs.time;

查询结果：[{'video_id': 2, 'time': datetime.time(0, 0, 15), 'original_text':
'大家好，首先我们说说什么是数据库，数据库都用在哪儿？所谓库，一般只集中存放大量
同类事物，比如水库、油库就是集中存放大量水或大量油。数据库，顾名思义就是包含大量
数据。正式的讲，包含关于某部门、机构、单位，或是某领域业务主题，或是某多项信息互
相关联的大量数据的集合，称作数据库。', 'summary_text': '介绍数据库的定义和基本含
义，说明数据库是包含大量相关联数据的集合。'}, {'video_id': 2, 'time': datetime.t
ime(0, 0, 51), 'original_text': '当今世界数据库非常广泛地应用在生产生活的方方面
面。比如，高等学校管理信息系统数据库，包含学生课程、学生选课数据、教师教学和评价
数据、科研论文和项目数据，也可以包括课程习题集、答案集以及试卷和学生答卷细节得
分的数据。', 'summary_text': '说明数据库广泛应用于高校管理系统，如学生选课、教师评
```

图 13 输入问题-生成 sql 语句-查询结果

Step3: 查询结果（来自数据库）：


查询结果展示：


```
[
  {
    "video_id": 2,
    "time": "00:00:15",
    "original_text": "大家好，首先我们说说什么是数据库.....",
    "summary_text": "介绍数据库的定义和基本含义。"
  },
  {
    "video_id": 2,
    "time": "00:04:03",
    "original_text": "我们把这类专门的通用软件称为数据库管理系统，英语是DBMS.....",
    "summary_text": "介绍数据库管理系统（DBMS）的定义及主流软件名称。"
  },
  ...]
```

查询结果共定位到视频 2 中多个时间段，涵盖数据库定义、实际应用、主流 DBMS 系统（如 PostgreSQL、Oracle、SQL Server 等）的讲解。

Step4: 模型自然语言回答:

系统将上述结果传入 `generate_natural_answer()` 函数生成中文回答:



```
核心实现 — python main.py — python — python main.py — 80x24

正如水库、油库一样，数据库也是更强调对数据的有效组织和管理。', 'summary_text': '
通过水库油库类比，强调数据库不仅是数据集合，更注重管理系统。'}, {'video_id': 2,
'time': datetime.time(0, 5, 1), 'original_text': '各行各业的业务系统都涉及大量数
据，都需要有效组织和管理相关的大量数据。以数据插入、删除、更新和查询为基础，简单
、安全、高效的实现各自关键的功能。抽取所有这些应用需求的共性，实现为通用的数据库
管理系统可以大大简化应用的开发。数据库管理系统，从应用对数据管理需求的共性特征出
发，能有效支持安全方便的数据管理，已经极大地并将继续推动各行各业的信息化发展。',
'summary_text': '说明 DBMS 通过通用功能支持各行业数据管理，推动信息化。'}, {'vi
deo_id': 2, 'time': datetime.time(0, 5, 42), 'original_text': '这一节我们讲了数
据库的概念，再见。', 'summary_text': '总结本节课程内容，结束语。'}]]

... 回答：根据查询结果，您可以从视频ID 2的开头开始观看（00:00:15处），这部分直接
介绍了数据库的基本定义和应用场景。若想快速了解核心概念，重点时间段如下：

1. **基础概念**：00:00:15（数据库定义）→ 00:03:37（课程专用定义）→ 00:04:03（DBM
S介绍）
2. **应用实例**：00:00:51起（高校、应急、社交等场景）
3. **管理系统核心**：00:04:34（类比水库强调管理）→ 00:05:01（DBMS作用总结）

建议按顺序观看，全程约5分42秒，可系统掌握数据库管理系统的核心知识。

请输入你的问题（或输入 exit 退出）：
> 
```

图 14 自然语言大模型生成中文回答